

**PENDEKATAN *HALF-FLIP 2D* UNTUK OPTIMASI
MULTI-MODAL ENGAGEMENT CLASSIFICATION
PADA PEMBELAJARAN DARING**

TESIS

**Karya tulis sebagai salah satu syarat
untuk memperoleh gelar Magister dari
Institut Teknologi Bandung**

**Oleh
ARI APRIANSYAH
NIM: 23523301
(Program Studi Magister Informatika)**



**INSTITUT TEKNOLOGI BANDUNG
Desember 2025**

ABSTRAK

PENDEKATAN *HALF-FLIP 2D* UNTUK OPTIMASI *MULTI-MODAL ENGAGEMENT CLASSIFICATION* PADA PEMBELAJARAN DARING

Oleh
Ari Apriansyah
NIM: 23523301
(Program Studi Magister Informatika)

Transformasi digital dalam dunia pendidikan telah mendorong terciptanya ekosistem pembelajaran berbasis teknologi yang semakin kompleks, khususnya melalui konsep *smart campus* yang mengintegrasikan teknologi informasi untuk meningkatkan efisiensi, mutu, dan fleksibilitas proses belajar. Pandemi COVID-19 mempercepat adopsi pembelajaran daring, yang hingga kini tetap digunakan dalam bentuk pembelajaran asinkron. Namun, metode ini menghadirkan tantangan baru dalam hal pemantauan dan evaluasi *engagement* pemelajar karena minimnya interaksi langsung antara pengajar dan pemelajar. Untuk menjawab permasalahan tersebut, penelitian ini mengusulkan sistem deteksi tingkat *engagement* berbasis *Facial Emotion Recognition* (FER) dan sikap visual (arah kepala dan kondisi mata) yang diimplementasikan pada pembelajaran daring berbasis video asinkron. Fokus penelitian diarahkan pada peningkatan *robustness* FER terhadap kondisi wajah yang mengalami oklusi parsial khususnya pada keadaan wajah tertutup tangan maupun keadaan wajah tidak menghadap ke depan (*non-frontal*), yang sering terjadi dalam konteks pembelajaran daring.

Permasalahan utama yang melatarbelakangi penelitian ini adalah keterbatasan sistem FER dalam menghadapi kondisi wajah yang tidak ideal. Oklusi wajah, misalnya ketika pemelajar menopang dagu dengan tangan atau menutupi area mata, dapat menghilangkan informasi penting pada bagian wajah seperti mata, alis, dan bibir. Demikian pula, orientasi wajah yang miring ke samping akibat perubahan arah pandangan dapat menurunkan akurasi sistem dalam mengenali emosi. Kondisi ini menghambat kemampuan sistem untuk menilai tingkat *engagement* secara tepat. Oleh karena itu, penelitian ini bertujuan mengembangkan metode *pre-processing* yang mampu mempertahankan atau merekonstruksi informasi wajah yang hilang akibat oklusi maupun orientasi *non-frontal*, sehingga sistem FER dapat lebih tangguh dalam skenario pembelajaran daring.

Metode yang diusulkan melibatkan serangkaian tahapan *pre-processing* berbasis pada pemrosesan citra gambar 2D. Pertama, wajah yang teroklusi objek tangan dikonversi ke bentuk *mesh* menggunakan pustaka MediaPipe. Selanjutnya dilakukan koreksi arah kepala (*roll correction*) untuk meluruskan wajah yang miring. Jika tangan terdeteksi, objek tangan tersebut dibuat blur dan kemudian di-

masking dengan warna merah, sementara wajah di-*masking* dengan warna putih. Hasil *masking* dibagi dua sesuai titik tengah wajah, lalu dihitung luas piksel putih pada masing-masing bagian. Bagian dengan piksel putih lebih banyak dipilih karena dianggap memiliki oklusi lebih sedikit. Berdasarkan hasil seleksi tersebut, wajah asli kemudian di-*stretching* mengikuti bentuk *mask* putih yang telah diluruskan. Wajah hasil *stretching* diduplikasi dan dikombinasikan sehingga tampak *frontal* tanpa adanya tangan yang menutupi. Hasil rekonstruksi wajah inilah yang kemudian diproses oleh model FER seperti CNN, DeepFace, dan FaceLib. Seluruh alur pemrograman metode ini dijelaskan dalam algoritma fungsi utama yang disajikan pada lampiran penelitian.

Hasil eksperimen menunjukkan bahwa metode yang diusulkan memberikan peningkatan performa yang signifikan pada kasus wajah dengan oklusi vertikal, yaitu ketika area atas wajah (mata, pipi, alis, dan sebagian mulut) tertutup tangan. Pada kondisi ini, model CNN mengalami peningkatan akurasi sebesar 33,79% dibandingkan *baseline* tanpa *pre-processing*, sementara DeepFace meningkat sebesar 14,29%. Hal ini mengindikasikan bahwa pendekatan yang digunakan mampu mempertahankan atau merekonstruksi informasi penting yang hilang akibat oklusi pada area wajah atas. Pada wajah *non-frontal*, metode ini juga memberikan peningkatan akurasi meskipun tidak signifikan. Sebaliknya, pada wajah dengan oklusi di area mulut, metode yang diusulkan tidak memberikan pengaruh berarti terhadap akurasi deteksi emosi. Bahkan beberapa model mengalami sedikit penurunan performa, seperti DeepFace (-2,93%) dan FaceLib (-2,92%). Fenomena ini menunjukkan bahwa area mulut berperan penting dalam pengenalan emosi seperti *happy*, *sad*, dan *fear* yang sangat bergantung pada gerakan bibir. Dengan demikian, kehilangan informasi pada area mulut masih menjadi tantangan utama dalam deteksi emosi yang akurat. Faktor lain yang turut memengaruhi hasil adalah akurasi *hand-detector* dari MediaPipe, yang terkadang gagal mendeteksi posisi tangan pada kondisi pencahayaan rendah atau pose tangan ekstrem.

Secara keseluruhan, penelitian ini menegaskan pentingnya integrasi antara deteksi emosi, arah pandangan, dan status mata dalam pengukuran *engagement* pelajar secara objektif pada pembelajaran daring. Metode *pre-processing* adaptif yang diusulkan terbukti mampu meningkatkan *robustness* FER terhadap kondisi oklusi parsial tertentu, terutama pada bagian atas wajah. Namun, keterbatasan masih ditemukan khususnya pada performa *hand-detector* yang gagal dalam mendeteksi tangan sehingga terjadi kesalahan dalam tugas untuk menghilangkan objek tangannya. Oleh karena itu, studi lanjutan dengan model *hand-detector* yang lebih *robust* pada beragam kondisi tangan, serta pendekatan *multi-modality* lainnya disarankan untuk mengonfirmasi efektivitas metode secara lebih umum dan memperluas penerapannya pada skenario dunia nyata, seperti sistem evaluasi otomatis pada *e-learning* atau platform pembelajaran interaktif. Dengan demikian, penelitian ini memberikan kontribusi penting dalam pengembangan sistem pemantauan *engagement* berbasis FER yang lebih tangguh dan relevan dengan kebutuhan pendidikan digital masa kini.

Kata kunci: *engagement* pembelajaran, pengenalan *multi-modal*, pengenalan emosi wajah, oklusi wajah, pembelajaran daring.

ABSTRACT

HALF-FLIP 2D APPROACH FOR OPTIMIZING MULTI-MODAL ENGAGEMENT CLASSIFICATION IN ONLINE LEARNING

By

Ari Apriansyah

NIM: 23523301

(Master's Program in Informatics)

Digital transformation in the field of education has driven the creation of increasingly complex technology-based learning ecosystems, particularly through the smart campus concept that integrates information technology to enhance the efficiency, quality, and flexibility of learning processes. The COVID-19 pandemic accelerated the adoption of online learning, which continues to be used today in the form of asynchronous learning. However, this method presents new challenges in monitoring and evaluating learner engagement due to the limited direct interaction between instructors and learners. To address these issues, this study proposes an engagement level detection system based on Facial Emotion Recognition (FER) and visual cues (head orientation and eye status), implemented in asynchronous video-based online learning. The research focuses on improving the robustness of FER under conditions of partially occluded faces, particularly when the face is covered by the hand or when the face is in a non-frontal position conditions that frequently occur in online learning settings.

The main problem underlying this research is the limitation of FER systems in handling non-ideal facial conditions. Facial occlusions, such as when learners rest their chin on their hand or cover the eye area, can remove important facial information such as the eyes, eyebrows, and lips. Similarly, non-frontal face orientations caused by changes in gaze direction can reduce the system's accuracy in recognizing emotions. These conditions hinder the system's ability to accurately assess engagement levels. Therefore, this study aims to develop a pre-processing method that can preserve or reconstruct facial information lost due to occlusion or non-frontal orientation, so that the FER system can be more robust in online learning scenarios.

The proposed method involves a series of pre-processing steps based on 2D image processing. First, faces occluded by hands are converted into mesh form using the MediaPipe library. Next, head-roll correction is applied to straighten tilted faces. If hands are detected, they are blurred and then masked in red, while the face is masked in white. The resulting mask is divided into two parts along the facial midline, and the white pixel area of each part is calculated. The section with more

white pixels is selected, as it is considered less occluded. Based on this selection, the original face is stretched to align with the white mask that has been corrected. The stretched face is then duplicated and combined to produce a frontal-looking face without hand occlusion. This reconstructed face is subsequently processed by FER models such as CNN, DeepFace, and FaceLib. The complete programming workflow of this method is detailed in the main algorithm presented in the appendix.

Experimental results show that the proposed method significantly improves performance in cases of vertical occlusion, where the upper facial area (eyes, cheeks, eyebrows, and part of the mouth) is covered by hands. Under these conditions, CNN achieved a 33.79% increase in accuracy compared to the baseline without pre-processing, while DeepFace improved by 14.29%. This indicates that the proposed approach can preserve or reconstruct critical facial information lost due to occlusion in the upper facial region. For non-frontal faces, the method also yielded accuracy improvements, though not significant. Conversely, for faces with occlusion in the mouth area, the proposed method did not produce meaningful improvements in emotion detection accuracy. In fact, some models experienced slight performance declines, such as DeepFace (-2.93%) and FaceLib (-2.92%). This phenomenon highlights the crucial role of the mouth region in recognizing emotions such as happy, sad, and fear, which rely heavily on lip movements. Thus, the loss of information in the mouth area remains a major challenge in accurate emotion detection. Another factor influencing results is the accuracy of MediaPipe's hand detector, which occasionally fails to detect hand positions under low-light conditions or extreme hand poses.

Overall, this research highlights the importance of integrating emotion detection, gaze direction, and eye status for objectively measuring learner engagement in online learning. The proposed adaptive pre-processing method has been shown to improve the robustness of FER against certain partial occlusion conditions, particularly in the upper-face region. However, limitations remain, especially in cases where the hand-detector fails to detect hands, leading to errors in the task of removing the occluding hand. Therefore, further studies using more robust hand-detectors capable of handling diverse hand conditions, as well as other multi-modality approaches, are recommended to confirm the effectiveness of the method more broadly and to extend its applicability to real-world scenarios, such as automated evaluation systems in e-learning or interactive learning platforms. Thus, this research provides an important contribution to the development of a more resilient FER-based engagement monitoring system that aligns with the needs of today's digital education.

Keywords: learning engagement, multi-modal recognition, facial emotion recognition, facial occlusion, online learning.

**PENDEKATAN *HALF-FLIP* 2D UNTUK OPTIMASI
MULTI-MODAL ENGAGEMENT CLASSIFICATION
PADA PEMBELAJARAN DARING**

Oleh
Ari Apriansyah
NIM: 23523301
(Program Studi Magister Informatika)

Institut Teknologi Bandung

Menyetujui
Tim Pembimbing

Tanggal 9 Desember 2025

Ketua

Anggota

Dr. Ir. Kusprasapta Mutijarsa, S.T., M.T.

Dr. Fadhil Hidayat, S.Kom., M.T.

PEDOMAN PENGGUNAAN TESIS

Tesis Magister yang tidak dipublikasikan terdaftar dan tersedia di Perpustakaan Institut Teknologi Bandung, dan terbuka untuk umum dengan ketentuan bahwa hak cipta ada pada penulis dengan mengikuti aturan HaKI yang berlaku di Institut Teknologi Bandung. Referensi kepustakaan diperkenankan dicatat, tetapi pengutipan atau peringkasan hanya dapat dilakukan seizin penulis dan harus disertai dengan kaidah ilmiah untuk menyebutkan sumbernya.

Sitasi hasil penelitian Tesis ini dapat di tulis dalam bahasa Indonesia sebagai berikut:

Apriansyah, Ari. (2025): *Pendekatan Half-Flip 2D untuk Optimasi Multi-Modal Engagement Classification Pada Pembelajaran Daring*, Tesis Program Magister, Institut Teknologi Bandung.

dan dalam bahasa Inggris sebagai berikut:

Apriansyah, Ari. (2025): *Half-Flip 2D Approach for Optimizing Multi-Modal Engagement Classification in Online Learning*, Master's Thesis, Institut Teknologi Bandung.

Memperbanyak atau menerbitkan sebagian atau seluruh tesis haruslah seizin Dekan Sekolah Pascasarjana, Institut Teknologi Bandung.

KATA PENGANTAR

Puji syukur penulis panjatkan ke hadirat Allah SWT atas limpahan rahmat, taufik, dan karunia-Nya, sehingga penulis dapat menyelesaikan penelitian dan penulisan tesis ini yang berjudul *Pendekatan Half-Flip 2D untuk Optimasi Multi-Modal Engagement Classification Pada Pembelajaran Daring*. Selama proses penelitian dan penulisan tesis ini, penulis mendapatkan banyak ilmu, bimbingan, dan dukungan dari berbagai pihak. Oleh karena itu, penulis menyampaikan terima kasih yang sebesar-besarnya kepada seluruh pihak yang telah membantu dalam pelaksanaan penelitian ini, baik secara langsung maupun tidak langsung. Ucapan terima kasih yang mendalam penulis sampaikan kepada Kementerian Komunikasi dan Digital Republik Indonesia melalui Program Beasiswa Magister Dalam Negeri yang telah memberikan kesempatan, dukungan, dan kepercayaan kepada penulis untuk menempuh pendidikan magister dan melaksanakan penelitian ini.

Penulis juga menyampaikan apresiasi kepada seluruh dosen, staf akademik, dan rekan-rekan di Sekolah Teknik Elektro dan Informatika, Institut Teknologi Bandung, atas ilmu, arahan, dan semangat kebersamaan yang diberikan selama masa studi. Tidak lupa, penulis mengucapkan terima kasih kepada keluarga tercinta atas doa, dukungan moral, dan motivasi yang tiada henti. Penulis menyadari bahwa tesis ini masih memiliki keterbatasan, oleh karena itu kritik dan saran yang membangun sangat diharapkan untuk perbaikan di masa mendatang. Semoga hasil penelitian ini dapat memberikan manfaat bagi pengembangan teknologi pembelajaran cerdas di Indonesia serta menjadi kontribusi kecil bagi kemajuan dunia pendidikan digital.

DAFTAR ISI

ABSTRAK	i
ABSTRACT	iii
PEDOMAN PENGGUNAAN TESIS	vi
KATA PENGANTAR	vii
DAFTAR ISI	viii
DAFTAR LAMPIRAN.....	x
DAFTAR GAMBAR DAN ILUSTRASI.....	xi
DAFTAR TABEL.....	xiii
DAFTAR SINGKATAN DAN LAMBANG	xiv
BAB I Pendahuluan.....	1
I.1 Latar Belakang.....	1
I.2 Rumusan Masalah.....	6
I.3 Tujuan Penelitian	6
I.4 Hipotesis	6
I.5 Batasan Penelitian.....	7
I.6 Kontribusi Penelitian	8
I.7 Sistematika Penulisan	8
BAB II Tinjauan Pustaka.....	10
II.1 <i>Affective Computing</i>	10
II.2 Deteksi <i>Engagement</i>	10
II.3 Deteksi <i>Engagement</i> dengan <i>Multi-Modal</i>	11
II.4 <i>Facial Emotion Recognition</i>	14
II.5 Oklusi pada <i>Facial Emotion Recognition</i>	16
II.6 <i>Mind Map</i> Alternatif Solusi Deteksi Emosi.....	18
II.7 Peta Literatur.....	19
BAB III Metodologi Penelitian.....	20
III.1 Identifikasi Masalah dan Motivasi.....	20
III.2 Definisi Tujuan dan Solusi	21
III.3 Perancangan dan Pengembangan.....	22
III.4 Demonstrasi	23
III.5 Evaluasi.....	24
III.6 Komunikasi.....	25
BAB IV Analisis dan Desain	26
IV.1 Lingkungan Penerapan	26
IV.2 Analisis Kebutuhan Sistem.....	26
IV.2.1 Kebutuhan Fungsional	27
IV.2.2 Kebutuhan Non-Fungsional.....	27
IV.2.3 Kebutuhan Pengguna	28
IV.2.4 Kebutuhan Perangkat Keras dan Perangkat Lunak.....	28
IV.3 Justifikasi Solusi	29
IV.4 Analisis Wajah.....	30
IV.5 Desain Solusi	31
IV.5.1 Desain Solusi Umum	31
IV.5.2 Desain Algoritma Program	32
IV.6 Desain Pengujian	35

IV.7	Pengembangan	37
IV.7.1	Perangkat Keras	37
IV.7.2	Perangkat Lunak	37
IV.7.2.1	Desain Halaman <i>Login</i>	38
IV.7.2.2	Desain Halaman Pembelajaran Asinkron	38
IV.7.2.3	Desain Halaman Data <i>Engagement</i>	39
IV.7.3	Pengembangan Metode Usulan	39
BAB V	Hasil dan Evaluasi	41
V.1	Hasil Metode Usulan	41
V.1.1	Hasil pada Wajah yang Tertutup Oklusi Tangan (Vertikal).....	42
V.1.2	Hasil pada Wajah dengan Kondisi Miring (<i>Non-Frontal</i>).....	47
V.1.3	Hasil pada Wajah yang Tertutup Oklusi Tangan (<i>Horizontal</i>).....	52
V.1.4	Hasil Komparasi terhadap Metode Frontalisasi Lain	54
V.2	Pembahasan	55
V.2.1	Performa <i>Face Detector</i> pada Model.....	55
V.2.2	Wajah yang Teroklusi oleh Tangan Sebagian	56
V.2.3	Wajah dengan Kondisi Miring (<i>Non-Frontal</i>).....	59
V.2.4	Oklusi Parsial pada Area Mulut.....	61
V.3	Aplikasi LMS.....	62
V.4	Implementasi FER pada LMS	65
BAB VI	Kesimpulan dan Saran	67
VI.1	Kesimpulan	67
VI.2	Saran	68
DAFTAR PUSTAKA		70
LAMPIRAN		76

DAFTAR LAMPIRAN

Lampiran A	Algoritma fungsi utama metode usulan (<i>Half-Flip 2D</i>).....	76
Lampiran B	Hasil pengujian evaluasi tingkat <i>engagement</i>	77

DAFTAR GAMBAR DAN ILUSTRASI

Gambar I.1	Contoh tangkapan layar wajah pemelajar saat pembelajaran daring dengan berbagai kondisi dan wajah yang teroklusi oleh tangan	5
Gambar II.1	Deteksi <i>engagement</i> pemelajar menggunakan FER, kedipan mata, dan gerakan kepala (Gupta dkk., 2023a)	13
Gambar II.3	Proses utama <i>facial emotion recognition</i>	14
Gambar II.4	(a) Keadaan wajah dengan oklusi <i>partial</i> oleh tangan, (b) keadaan wajah dengan oklusi total (Jain & Learned-Miller, 2010)	17
Gambar II.5	<i>Mind map</i> deteksi emosi pemelajar pada media pembelajaran daring	18
Gambar II.6	<i>Mind map</i> tentang cara mengatasi masalah oklusi pada FER	19
Gambar II.7	Peta literatur deteksi <i>engagement</i> pada pembelajaran daring	19
Gambar III.1	<i>Design Science Research Methodology</i>	20
Gambar IV.1	Alur penerapan mekanisme umpan balik pada LMS	26
Gambar IV.2	Contoh hasil analisis wajah dengan paramater arah pandangan mata, arah kepala, dan emosi wajah	30
Gambar IV.3	Contoh kondisi wajah yang arah kepala dan mata tidak menghadap monitor atau menghadap kesamping (gambar dibuat dengan AI)	30
Gambar IV.4	Gambaran umum ajuan solusi sistem	31
Gambar IV.5	Detail teknis dan fokus penelitian pada bagian <i>pre-processing</i>	31
Gambar IV.6	Diagram alir algoritma kondisi penggunaan FER untuk menentukan <i>engagement</i> pemelajar	32
Gambar IV.7	Skema metode usulan dalam penanganan masalah oklusi dan wajah <i>non-frontal</i> pada wajah	34
Gambar IV.8	Proses penambahan tangan sintesis, (a) gambar asli, (b) tangan sintesis, (c) hasil augmentasi	36
Gambar IV.9	Data wajah untuk pengujian, (a) wajah dengan oklusi tangan, (b) wajah non-frontal	37
Gambar IV.10	Rancangan desain halaman <i>login</i>	38
Gambar IV.11	Rancangan halaman pembelajaran asinkron	38
Gambar IV.12	Rancangan halaman data <i>engagement</i>	39
Gambar IV.13	Langkah pada metode usulan	39
Gambar V.1	Hasil percobaan metode usulan, (a) data wajah dengan oklusi tangan, (b) wajah dalam keadaan non-frontal	41
Gambar V.2	Perbandingan probabilitas emosi pada gambar sebelum dan sesudah diterapkan metode usulan	42
Gambar V.3	Visualisasi perbandingan akurasi data sebelum dan sesudah penerapan metode usulan pada data wajah dengan oklusi tangan menggunakan model CNN	43
Gambar V.4	Visualisasi perbandingan akurasi data sebelum dan sesudah penerapan metode usulan pada data wajah dengan oklusi tangan menggunakan model DeepFace	44
Gambar V.5	Visualisasi perbandingan akurasi data sebelum dan sesudah penerapan metode usulan pada data wajah dengan oklusi tangan menggunakan model FaceLib	45

Gambar V.6	Visualisasi perbandingan akurasi data sebelum dan sesudah penerapan metode usulan pada data wajah dengan oklusi tangan menggunakan model SVM.....	46
Gambar V.7	Hasil akurasi data wajah <i>non-frontal</i> dengan CNN.....	48
Gambar V.8	Hasil akurasi data wajah <i>non-frontal</i> dengan DeepFace.....	49
Gambar V.9	Hasil akurasi data wajah <i>non-frontal</i> dengan FaceLib.....	50
Gambar V.10	Hasil akurasi data wajah <i>non-frontal</i> dengan SVM	51
Gambar V.11	Kondisi wajah tertutup tangan pada bagian bawah (mulut).....	52
Gambar V.12	Hasil penerapan metode usulan terhadap wajah dengan oklusi tangan pada bagian bawah wajah.....	53
Gambar V.13	Metode <i>frontalization</i> wajah 2D oleh Tsai dkk., (2021).....	54
Gambar V.14	Hasil komparasi, (A) gambar <i>input</i> , (B) metode usulan, (C) metode oleh Tsai dkk., (2021).....	54
Gambar V.15	Hasil metode usulan, (A) kondisi berhasil, (B) kondisi gagal	58
Gambar V.16	Arsitektur DeepFace (Taigman dkk., 2014).....	59
Gambar V.17	Halaman <i>login</i>	62
Gambar V.18	Halaman <i>dashboard</i>	62
Gambar V.19	Halaman akses materi pembelajaran asinkron	63
Gambar V.20	Data <i>engagement</i> pemelajar	63
Gambar V.21	Data persentase emosi dan kesimpulan <i>engagement</i> pemelajar.....	64
Gambar V.22	Grafik perubahan emosi pemelajar	64
Gambar V.23	Hasil intepretasi hasil menggunakan LLM	65
Gambar V.24	Keterangan hasil analisis wajah pemelajar per <i>frame</i> , (a) kondisi <i>highly engaged</i> , wajah lurus ke layar tanpa halangan, (b) kondisi <i>highly engaged</i> , wajah lurus ke layar dengan halangan tangan, (c) kondisi <i>boredom</i> , wajah tidak menghadap ke layar, (d) kondisi <i>sleepy</i> , mata tertutup, (e) kondisi <i>boredom</i> kepala ditopang tangan	65

DAFTAR TABEL

Tabel III.1 Tahap identifikasi masalah dan motivasi	20
Tabel III.2 Tahap tujuan dan solusi.....	21
Tabel III.3 Tahap perancangan dan pengembangan.....	22
Tabel III.4 Tahapan demonstrasi.....	23
Tabel III.5 Tahap evaluasi.....	24
Tabel III.6 Tahap komunikasi	25
Tabel IV.1 Alternatif solusi untuk deteksi emosi pemelajar	29
Tabel V.1 Hasil akurasi data wajah dengan oklusi tangan dengan CNN.....	43
Tabel V.2 Hasil akurasi data wajah dengan oklusi tangan dengan DeepFace	44
Tabel V.3 Hasil akurasi data wajah dengan oklusi tangan dengan FaceLib	45
Tabel V.4 Hasil akurasi data wajah dengan oklusi tangan dengan SVM	46
Tabel V.5 Hasil akurasi data wajah miring (<i>non-frontal</i>) dengan CNN	48
Tabel V.6 Hasil akurasi data wajah miring (<i>non-frontal</i>) dengan DeepFace	49
Tabel V.7 Hasil akurasi data wajah miring (<i>non-frontal</i>) dengan FaceLib	50
Tabel V.8 Hasil akurasi data wajah miring (<i>non-frontal</i>) dengan SVM.....	51
Tabel V.9 Jumlah data uji wajah dengan oklusi tangan (<i>horizontal</i>).....	52
Tabel V.10 Performa model dalam mendeteksi wajah pada wajah yang teroklusi tangan pada bagian mulut	53
Tabel V.11 Hasil pengujian metode usulan pada wajah yang teroklusi tangan pada bagian mulut.....	53
Tabel V.12 Hasil komparasi metode <i>frontalization</i>	54
Tabel V.13 Hasil ringkasan beberapa skenario pengujian <i>engagement</i> pemelajar	66

DAFTAR SINGKATAN DAN LAMBANG

SINGKATAN	Nama	Pemakaian pertama kali pada halaman
CNN	<i>Convolutional Neural Network</i>	3
CNN-RF	<i>Convolutional Neural Network - Random Forest</i>	34
COVID-19	<i>Corona Virus Disease 2019</i>	1
DL	<i>Deep Learning</i>	4
DSRM	<i>Design Science Research Methodology</i>	8
FER	<i>Facial Emotions Recognition</i>	3
IoT	<i>Internet of Things</i>	2
LBP	<i>Local Binary Pattern</i>	14
LMS	<i>Learning Management System</i>	1
MOOC	<i>Massive Online Open Course</i>	2
SVM	<i>Support Vector Machine</i>	21

LAMBANG

BAB I Pendahuluan

Bab ini membahas berbagai dasar dan pedoman yang menjadi fokus utama penelitian. Tujuannya adalah untuk memberikan pemahaman menyeluruh mengenai penelitian serta urgensinya dalam mencapai tujuan yang telah ditetapkan.

I.1 Latar Belakang

Transformasi digital dalam dunia pendidikan menjadi langkah penting bagi institusi pendidikan tinggi untuk beradaptasi dengan era revolusi industri 4.0. Salah satu arah pengembangan yang banyak diambil oleh berbagai universitas dan lembaga pendidikan adalah penerapan konsep *smart campus*, dimana teknologi informasi digunakan untuk meningkatkan efisiensi, mutu, dan fleksibilitas pembelajaran. Pandemi COVID-19 menjadi pemicu utama bagi percepatan transformasi ini, dimana kejadian tersebut memaksa sistem pendidikan di seluruh dunia beralih secara mendadak ke metode pembelajaran daring. Perubahan ini menghadirkan berbagai tantangan, terutama dalam menjaga kualitas interaksi antara pengajar dan peserta didik.

Setelah pandemi dinyatakan berakhir dan kegiatan belajar mengajar tatap muka kembali dilaksanakan, pembelajaran daring tetap dijadikan bagian dari sistem pendidikan modern, khususnya dalam bentuk pembelajaran asinkron yang merupakan metode pembelajaran daring dimana peserta dan pengajar tidak harus hadir atau berinteraksi pada waktu yang sama dan salah satu bentuk aplikasi yang biasanya dipakai dalam pembelajaran daring adalah *learning management system* (LMS). Melalui LMS, materi pembelajaran dapat disampaikan dalam bentuk dokumen maupun video sehingga peserta didik memiliki fleksibilitas dalam menentukan waktu belajar, namun sistem ini juga menimbulkan permasalahan lain, yakni berkurangnya interaksi langsung antara pengajar dan peserta didik. Akibatnya, pengajar kesulitan menilai tingkat fokus, keseriusan, serta engagement peserta didik selama mengakses materi pembelajaran (Peterson, 2023).

Untuk mengatasi keterbatasan tersebut, diperlukan mekanisme umpan balik berbasis teknologi yang mampu menyimpulkan tingkat *engagement* peserta didik dengan memanfaatkan data emosi dalam berbagai bentuk seperti teks, suara, atau

visual (Yu dkk., 2024). Salah satu pendekatan yang banyak digunakan adalah analisis sentimen berbasis teks, dimana emosionalitas peserta didik dapat diukur melalui komentar atau tanggapan dalam forum pembelajaran daring (Xu, 2023). Beberapa penelitian tentang penerapan analisis sentimen untuk mengetahui emosi dari pemelajar telah dilakukan oleh beberapa peneliti. Peneliti X. Zhang & Qin, (2022) membuat sistem yang menerapkan analisis sentimen untuk mengevaluasi emosi pemelajar pada pelajaran Ideologi dan Politik dalam *platform* daring. Pendekatan analisis sentimen juga telah dilakukan oleh Mao dkk., (2023) untuk mengevaluasi tingkat emosional pemelajar dalam pelajaran *Internet of Things* (IoT). Walaupun demikian, pendekatan analisis sentimen dinilai kurang tepat untuk dijadikan aspek penilaian utama untuk mendapatkan data emosi pemelajar, karena dimungkinkan untuk terjadinya emosi palsu dari pemelajar dalam tulisannya (Khoshnam & Baraani-Dastjerdi, 2022).

Bentuk mekanisme umpan balik yang lainnya adalah berbasis *audio*. Berdasarkan referensi penelitian lampau, Bao dkk., (2024) menggabungkan fitur *audio* dan gerakan mata untuk mengevaluasi emosi pemelajar pada *massive daring open course* (MOOC). Mereka merancang sistem yang dapat mengklasifikasikan emosi seperti minat, kebahagiaan, kebingungan, dan kebosanan dengan hasil akurasi sebesar 81,90%. Penelitian lain yang menggunakan fitur *audio* dalam mendeteksi emosi pemelajar pada pembelajaran daring adalah Bekmanova dkk., (2022), didasari oleh pembelajaran jarak jauh karena COVID-19, mereka membangun sistem yang dapat mendeteksi emosi positif dan negatif dari ucapan lisan pemelajar dengan bahasa Kazakh dengan hasil akurasi sebesar 79,7%. Berdasarkan hasil penelitian-penelitian di atas, membuktikan bahwa *audio* dapat digunakan sebagai basis penilaian untuk memberikan masukan dari pemelajar kepada pengajar berupa data emosi pemelajar. Walaupun demikian, penggunaan *audio* dalam deteksi emosi pemelajar pada pembelajaran daring memiliki sejumlah masalah, seperti penggunaan fitur *audio* yang menyebabkan penurunan akurasi jika digabungkan dengan fitur lain (Pan dkk., 2024), lalu adanya batasan kuantitas terhadap *database* yang akan digunakan sebagai data latih (Zhu-Zhou dkk., 2022), hingga mahalnya biaya komputasi pengolahan sinyal *audio* (Liu dkk., 2021).

Pendekatan lain yang semakin populer adalah berbasis visual. Memanfaatkan teknologi *computer vision*, banyak penelitian yang menggunakan teknologi *facial emotion recognition* (FER) untuk mendapatkan data emosi dari pengamatan emosi wajah pemelajar pada lingkungan pembelajaran daring. Bhardwaj dkk., (2021) merancang sistem untuk menghitung tingkat *engagement* pemelajar dengan menerapkan FER selama kelas daring dan mendapatkan hasil akurasi sebesar 93,6% dalam klasifikasi emosinya menggunakan algoritma *Convolutional Neural Network* (CNN). Penerapan FER dalam lingkungan pendidikan daring lainnya juga pernah dilakukan oleh Gupta dkk., (2023c). Mereka membangun sistem FER yang dapat mendeteksi tingkat *engagement real-time* dengan menganalisis emosi wajah, lalu mengklasifikasikan pemelajar menjadi “Terlibat” atau “Tidak Terlibat” berdasarkan keadaan emosinya. Algoritma yang mereka gunakan untuk klasifikasi emosi pemelajar adalah algoritma ResNet-50 dan mendapatkan hasil mencapai akurasi 92,3% dalam skenario *real-time*. Berdasarkan hal tersebut, dibandingkan dengan solusi alternatif seperti analisis sentimen dan pengenalan suara, penerapan FER pada pembelajaran daring baik sinkron maupun asinkron bisa dijadikan sebagai solusi yang paling logis untuk menyelesaikan masalah kebutuhan mekanisme umpan balik dari pemelajar pada lingkungan pembelajaran daring baik dari sisi batasan-batasan tiap solusi yang ada maupun dari biaya dan beban komputasi.

Walaupun demikian, penerapan FER pada pembelajaran daring juga mempunyai beberapa keterbatasan, terutama dalam keadaan oklusi, seperti wajah yang tertutup oleh tangan, kacamata, atau objek lain (Li dan Deng, 2022). Kondisi ini dapat mengurangi akurasi dalam mendeteksi emosi secara tepat, sehingga sistem mungkin menghasilkan prediksi yang kurang akurat atau bahkan keliru dalam menginterpretasikan emosi pengguna (Mensah dkk., 2024). Selain itu, variasi pencahayaan dan sudut pandang kamera yang tidak seragam juga dapat memengaruhi performa model dalam mengenali emosi wajah secara konsisten.

Beberapa penelitian yang telah lampau mencoba untuk mengatasi masalah oklusi pada penerapan FER pada lingkungan nyata. Ada beberapa cara untuk mengatasi oklusi pada penerapan FER yang telah dilakukan peneliti, antara lain dengan

menerapkan teknik pemrosesan citra seperti merekonstruksi bagian wajah yang terhalang (Poux dkk., 2022), menggunakan model *deep learning* (DL) yang dilatih dengan data augmentasi oklusi agar lebih *robust* terhadap data oklusi (X. Zhang dkk., 2022), serta memanfaatkan multi-modalitas, seperti kombinasi informasi dari gambar dan data lainnya, misalnya gabungan data wajah dan suara (Freire-obregón dan Castrillón-santana, 2024 dan Mamieva dkk., 2023). Meskipun berbagai metode telah dikembangkan untuk mengatasi oklusi pada penerapan FER, solusi-solusi di atas merupakan teknik yang memerlukan komputasi yang kompleks, sehingga mengakibatkan kenaikan latensi pada prosesnya.

Alternatif lain yang lebih ringan adalah perbaikan pada tahap *pre-processing* data. Cao dkk., (2021) mengusulkan metode berbasis penggabungan setengah wajah dalam bentuk 3D untuk memperbaiki pengenalan emosi pada wajah yang tertutup sebagian. Metode ini terbukti meningkatkan akurasi, tetapi teknik berbasis 3D memerlukan sumber daya komputasi tinggi (Morar dkk., 2017). Untuk mengatasi keterbatasan ini, penelitian ini akan mengajukan metode *pre-processing* baru yang menduplikasi setengah wajah yang tidak teroklusi untuk merekonstruksi wajah penuh dalam format dua dimensi. Pendekatan yang diberi nama *Half-Flip 2D* ini diharapkan mampu mempertahankan ketepatan deteksi emosi seperti pengolahan 3D, namun dengan kompleksitas komputasi yang jauh lebih rendah.

Data emosi hasil klasifikasi model FER selanjutnya akan menjadi salah satu paramater masukan untuk menentukan tingkat *engagement* pemelajar. Berdasarkan temuan Sukumaran & Manoharan, (2024), klasifikasi tingkat *engagement* melalui pendekatan *multi-modal* yang memanfaatkan data emosi wajah, orientasi kepala, dan kondisi mata telah terbukti efektif dalam mencapai deteksi yang akurat. Penelitian ini mengadopsi parameter *multi-modal* serupa dengan yang digunakan dalam penelitian tersebut. Berbeda dengan penelitian dari Sukumaran & Manoharan, (2024), penelitian ini akan menambahkan tahapan *pre-processing* dengan metode usulan sebelum proses klasifikasi emosi wajah. Tahapan ini meliputi penghilangan objek oklusi berupa tangan dan penerapan teknik *frontalization* wajah. Dengan demikian, akurasi FER tetap tinggi meskipun wajah

teroklusi atau tidak berada dalam posisi frontal, sehingga meningkatkan kinerja keseluruhan sistem deteksi *engagement*.

Aplikasi pembelajaran daring akan dirancang secara khusus sebagai sarana pengujian terhadap metode penilaian tingkat *engagement* pemelajar. Aplikasi tersebut akan mengintegrasikan beberapa modalitas yang memanfaatkan hasil deteksi emosi wajah melalui FER serta analisis indikator visual, termasuk arah gerakan kepala dan kondisi mata. Materi pembelajaran yang digunakan dibatasi pada rekaman video perkuliahan daring, yang kemudian dianalisis oleh sistem untuk mengidentifikasi emosi wajah pemelajar sebagai dasar penentuan tingkat keterlibatan dalam proses pembelajaran asinkron. Hasil penilaian *engagement* yang dihasilkan diharapkan dapat berfungsi sebagai data umpan balik sekaligus menawarkan solusi praktis dalam mengatasi keterbatasan interaksi yang kerap muncul pada model pembelajaran daring berbasis asinkron.



Gambar I.1 Contoh tangkapan layar wajah pemelajar saat pembelajaran daring dengan berbagai kondisi dan wajah yang teroklusi oleh tangan

Penelitian ini mengembangkan metode *pre-processing* data wajah yang mengalami oklusi, khususnya ketika wajah tertutup oleh tangan sebagaimana ditunjukkan pada Gambar I.1. Kondisi ini sering kali terjadi dalam konteks pembelajaran daring, dimana pemelajar secara alami menutupi sebagian wajah mereka karena berbagai alasan, seperti keluhan kesehatan pada leher atau kepala (Beekman dkk., 2002), maupun akibat faktor psikologis seperti upaya untuk lebih fokus atau merasa bosan. Metode *pre-processing* yang diusulkan bertujuan untuk meningkatkan probabilitas emosi pada wajah yang tidak menghadap lurus ke depan maupun teroklusi oleh tangan agar tetap dapat diklasifikasikan secara optimal dalam sistem FER selama pembelajaran daring berlangsung.

I.2 Rumusan Masalah

Berdasarkan latar belakang di atas, bahwa penerapan sistem FER pada media pembelajaran daring untuk mengetahui tingkat *engagement* pemelajar melalui modalitas visual masih memiliki kekurangan terutama pada pembelajaran *asynchronous*, yaitu adanya masalah penurunan akurasi FER pada kondisi wajah yang teroklusi tangan, maka dirumuskan suatu masalah pada penelitian ini, yaitu:

1. Bagaimana mengatasi oklusi wajah pada pengukuran klasifikasi tingkat *engagement* pemelajar yang berbasis *multi-modal* yaitu emosi wajah, arah kepala, dan kondisi mata ?
2. Apakah *pre-processing* gambar 2D yang memanfaatkan data setengah wajah dapat meningkatkan probabilitas emosi wajah pemelajar yang teroklusi ?
3. Bagaimana mengembangkan aplikasi untuk menampilkan hasil pengukuran tingkat *engagement* pemelajar ?

I.3 Tujuan Penelitian

Tujuan dari penelitian ini adalah sebagai berikut:

1. Mengembangkan teknik *pre-processing* gambar 2D berbasis pemanfaatan setengah wajah untuk meningkatkan akurasi klasifikasi emosi, baik pada kondisi wajah teroklusi maupun tidak frontal, sehingga mendukung optimasi performa sistem klasifikasi *engagement multi-modal*.
2. Mengevaluasi efektivitas metode *pre-processing* gambar 2D berbasis setengah wajah dalam meningkatkan akurasi dan probabilitas klasifikasi emosi pada kondisi wajah teroklusi.
3. Merancang dan membangun aplikasi yang menampilkan hasil pengukuran tingkat *engagement* pemelajar, guna mendukung implementasi sistem klasifikasi *engagement* dalam pembelajaran daring.

I.4 Hipotesis

Pada penelitian ini disusun hipotesis yang berdasarkan premis-premis sebagai berikut:

1. Area-area penting pada wajah, seperti mata, mulut, dan alis menjadi tertutup sehingga informasi visual yang dibutuhkan untuk mengenali emosi tidak dapat terekstraksi secara optimal (Ruan dkk., 2022a).
2. Pose kepala yang miring (tidak menghadap ke depan) juga mengakibatkan menurunnya akurasi FER karena terjadi *self-occlusion* dan perubahan tampilan geometri fitur wajah pada gambar, sehingga sistem sulit mengenali emosi secara akurat (Engin dkk., 2018).
3. *Hard symmetry* bisa digunakan untuk membantu sistem FER mengatasi permasalahan oklusi (Ullah dkk., 2024).

Berdasarkan premis-premis tersebut, disusun hipotesis sebagai berikut:

1. Penghapusan objek oklusi seperti tangan dan penerapan *frontalization* pada wajah miring dapat memperbaiki akurasi FER. Fitur-fitur wajah penting yang awalnya tertutup atau hilang bisa dikembalikan dengan teknik *hard symmetry* sehingga model FER dapat mengekstraksi fitur wajah dengan lengkap dan meningkatkan akurasi klasifikasi emosinya.

I.5 Batasan Penelitian

Berikut batasan-batasan yang ditetapkan untuk penelitian ini.

1. Aplikasi pembelajaran daring yang akan dibuat mengacu pada LMS dengan fitur yang hanya berfokus pada pembelajaran asinkron.
2. Penerapan sistem FER hanya pada pembelajaran asinkron yang berbentuk video rekaman paparan perkuliahan.
3. Sikap visual yang dinilai hanya berdasarkan arah kepala dan mata pemelajar.
4. Bentuk oklusi yang diteliti hanya pada kondisi sebagian wajah tertutup tangan (*vertikal*) dan wajah dalam keadaan miring (tidak menghadap ke depan), karena keadaan sebagian wajah tertutup tangan lazim dilakukan oleh pemelajar dalam menjalani pembelajaran secara daring baik karena masalah kesehatan leher atau kepala (Beekman dkk., 2002).

I.6 Kontribusi Penelitian

Penelitian ini diharapkan dapat memberikan kontribusi baik terhadap penyelesaian masalah maupun dalam bidang ilmu pengetahuan. Adapun kontribusi pada penelitian ini adalah menghasilkan sebuah pendekatan baru berupa metode *pre-processing* pada gambar wajah dengan hanya menggunakan data setengah wajah dalam format dua dimensi untuk meningkatkan akurasi dalam pengenalan emosi wajah pada kondisi teroklusi tangan ataupun dalam keadaan wajah miring. Temuan ini diberi nama teknik *Half-Flip 2D*.

I.7 Sistematika Penulisan

Sistematika penulisan tesis akan dibagi menjadi lima bab yang diawali dengan penjabaran umum di setiap rinciannya.

Bab I Pendahuluan

Memberikan penjelasan mengenai latar belakang dilakukannya penelitian. Dari latar belakang yang telah dijabarkan, selanjutnya disusun suatu rumusan masalah, tujuan penelitian, batasan penelitian, kebaruan dan kontribusi penelitian serta sistematika penulisan.

Bab II Tinjauan Pustaka

Menjelaskan mengenai gambaran tinjauan literatur dan kajian ilmu yang digunakan untuk mendukung suatu penelitian. Tinjauan pustaka ini selanjutnya dimanfaatkan dalam mengidentifikasi suatu permasalahan, konsep, dan ilmu pengetahuan untuk mendapatkan solusi dari penelitian yang akan dilakukan.

Bab III Metodologi Penelitian

Pembahasan terkait dengan metodologi yang akan digunakan di dalam penelitian. *Design Science Research Methodology* (DSRM) dipilih sebagai metode dalam penulisan tesis ini. Terdapat enam tahapan utama di dalam DSRM, yaitu identifikasi masalah & motivasi, menentukan tujuan solusi, perancangan & pengembangan, demonstrasi, evaluasi, dan komunikasi.

Bab IV Analisis dan Desain

Menjelaskan hasil analisis terhadap beberapa alternatif solusi beserta alasan pemilihan solusi yang dianggap paling sesuai dengan kebutuhan sistem. Selain itu, bab ini juga memaparkan rancangan dari solusi terpilih, meliputi alur proses, dan komponen utama yang akan digunakan dalam pengembangan sistem.

Bab V Hasil dan Evaluasi

Menyajikan hasil implementasi dari desain yang telah dibuat pada bab sebelumnya. Pada bagian ini dijelaskan kinerja sistem yang telah dibangun, hasil pengujian yang dilakukan, serta evaluasi terhadap pencapaian tujuan yang telah ditetapkan. Bab ini juga menampilkan tanggapan atau analisis terhadap hasil yang diperoleh untuk memastikan bahwa sistem berfungsi sesuai dengan kebutuhan dan spesifikasi yang direncanakan.

Bab VI Kesimpulan dan Saran

Memberikan penjelasan mengenai kesimpulan dari penelitian yang telah dilakukan. Selain itu, juga akan disampaikan mengenai beberapa saran yang bisa menjadi pertimbangan untuk dilakukannya penelitian lanjutan.

BAB II Tinjauan Pustaka

Bab ini mencakup tinjauan pustaka yang berperan sebagai acuan penelitian dalam mencapai tujuan penelitian yang telah didefinisikan. Tinjauan pustaka dilakukan terhadap referensi eksternal yang kredibel dan sesuai dengan kebutuhan pengerjaan tesis.

II.1 *Affective Computing*

Affective computing adalah bidang *interdisipliner* dalam kecerdasan buatan yang berfokus pada pengenalan, interpretasi, dan simulasi emosi manusia oleh komputer. Konsep ini pertama kali diperkenalkan oleh Rosalind Picard pada tahun 1995, yang menekankan pentingnya emosi dalam interaksi manusia dan teknologi. Dengan kemajuan teknologi, *affective computing* kini diterapkan dalam berbagai domain, seperti interaksi manusia-mesin, perawatan kesehatan, pendidikan, dan hiburan. Kemampuan sistem untuk mengenali dan merespons emosi pengguna dapat meningkatkan pengalaman pengguna secara signifikan (Afzal dkk., 2024).

Dalam dunia pendidikan *affective computing* memiliki peran, terutama dalam meningkatkan pengalaman belajar yang lebih personal dan adaptif (Villegas-Ch dkk., 2024). Teknologi ini memungkinkan sistem pembelajaran digital untuk mengenali emosi pelajar melalui emosi wajah, nada suara, atau bahkan respons fisiologis (Yu dkk., 2024). Dengan memanfaatkan *affective computing*, sistem dapat menyesuaikan materi dan metode pembelajaran sesuai dengan kondisi emosional pelajar, misalnya dengan memperlambat penjelasan jika pelajar terlihat kebingungan atau memberikan motivasi saat mereka merasa frustrasi (Shi, 2024). Hal ini dapat meningkatkan efektivitas pembelajaran dan membantu pelajar lebih fokus serta termotivasi dalam proses belajar (Lin dkk., 2022).

II.2 *Deteksi Engagement*

Deteksi *engagement* dalam pembelajaran daring semakin memperoleh perhatian seiring dengan pesatnya adopsi teknologi digital di bidang pendidikan. Tujuan utama pendekatan ini adalah mengidentifikasi tingkat partisipasi dan konsentrasi peserta didik melalui analisis indikator *non-verbal*, seperti emosi wajah, arah

tatapan, dan gerakan kepala, yang diproses menggunakan teknik *computer vision*. Dengan memanfaatkan model klasifikasi berbasis citra maupun video, sistem deteksi *engagement* dapat menghasilkan estimasi yang lebih objektif dan *real-time*, sehingga mendukung pendidik dalam memahami dinamika interaksi di kelas virtual.

Gupta dkk., (2023c) mengembangkan sistem *real-time* berbasis *deep learning* yang berfokus pada pengenalan emosi wajah untuk mendeteksi keterlibatan siswa selama sesi daring. Sistem tersebut mengintegrasikan model Faster R-CNN untuk deteksi wajah dan CNN untuk klasifikasi emosi, kemudian menghitung *engagement index* (EI) secara periodik berdasarkan emosi yang teridentifikasi. Temuan penelitian ini menegaskan bahwa emosi wajah merupakan indikator yang efektif dalam membedakan siswa yang *engaged* dan *disengaged*.

Pendekatan *unimodal* terbukti efisien karena relatif mudah diimplementasikan secara *real-time* serta tidak memerlukan sensor tambahan selain kamera bawaan perangkat siswa. Chen, Zhou, dkk., (2023) meninjau berbagai metode deteksi *engagement* berbasis tunggal dan menyimpulkan bahwa modalitas visual, seperti deteksi arah tatapan, mikro emosi wajah, dan pergerakan kepala, merupakan pendekatan yang paling banyak digunakan dalam sistem otomatisasi *engagement* pada platform pembelajaran daring. Metode *unimodal* dinilai sesuai untuk skenario berskala besar yang menghadapi keterbatasan privasi maupun sumber daya perangkat keras.

Meskipun demikian, sejumlah penelitian menyoroti keterbatasan pendekatan *unimodal*, antara lain rendahnya ketahanan terhadap *noise* lingkungan serta kesulitan dalam membedakan emosi yang memiliki kemiripan visual (Chen, Zhou, dkk., 2023). Walaupun terdapat keterbatasan tersebut, dalam konteks pendidikan daring yang menuntut solusi komputasi ringan, pendekatan *unimodal* tetap menjadi pilihan populer baik dalam penelitian maupun aplikasi praktis.

II.3 Deteksi *Engagement* dengan *Multi-Modal*

Sebagai respons terhadap keterbatasan metode *unimodal*, berbagai penelitian terbaru cenderung mengadopsi pendekatan multimodal dan integrasi beberapa


model *deep learning* untuk memperoleh hasil deteksi engagement yang lebih komprehensif dan akurat pada pembelajaran daring. Santoni dkk., (2024) dalam artikelnya “*Automatic Detection of Students’ Engagement During Online Learning: A Bagging Ensemble Deep Learning Approach*” meneliti penggunaan teknik *bagging ensemble* dengan model 1D CNN dan ResNet. Temuan mereka menunjukkan bahwa kombinasi beberapa model deep learning menghasilkan akurasi deteksi keterlibatan yang lebih tinggi dibandingkan pendekatan berbasis model tunggal, serta mampu beradaptasi terhadap variasi perilaku siswa di lingkungan virtual.

Selain itu, Karimah & Hasegawa, (2022) dalam artikel “*Automatic engagement estimation in smart education/learning settings: A systematic review of engagement definitions, datasets, and methods*” menjelaskan bahwa deteksi engagement otomatis di lingkungan pembelajaran cerdas umumnya memanfaatkan kombinasi isyarat *non-verbal* seperti emosi wajah, gerakan tubuh, sinyal fisiologis, dan *log* aktivitas sistem untuk menghasilkan estimasi keterlibatan yang lebih andal. Kajian ini menegaskan bahwa pendekatan multimodal dan pemanfaatan metode *deep learning* cenderung memberikan performa lebih baik dibandingkan teknik konvensional, terutama pada konteks pembelajaran daring yang sangat dinamis.

Gupta dkk., (2023c) juga mengusulkan pendekatan *deep learning* berbasis pengenalan emosi wajah untuk mendeteksi *engagement* pembelajaran daring secara *real-time* dengan menghitung *engagement index* (EI) dari emosi yang terdeteksi sepanjang sesi pembelajaran. Dalam studi tersebut, beberapa arsitektur CNN seperti Inception-V3, VGG19, dan ResNet-50 dibandingkan, dan hasilnya menunjukkan bahwa model *deep learning* mampu mengklasifikasikan status *engaged* dan *disengaged* dengan akurasi tinggi sekaligus tetap cukup efisien untuk diimplementasikan pada skenario kelas daring *real-time*.

Deteksi *engagement* pemelajar bisa menggunakan *head pose* (Gupta dkk., 2023b) dan *eye gaze* (Tian dkk., 2024). Dengan teknik tersebut, sistem bisa menyimpulkan keadaan pemelajar apakah fokus terhadap pelajaran atau tidak. Peneliti Gupta dkk., (2023a), menggabungkan *head pose* dan *eye blink* (Gambar II.1) dalam mendeteksi *engagement* pemelajar. Dilatarbelakangi atas meningkatnya permintaan

pembelajaran daring selama pandemi COVID-19, Gupta dkk., (2023a) mengusulkan sistem *student engagement detection* untuk memberikan umpan balik. Sistem ini dirancang untuk mendukung *e-learning platforms* dengan mendeteksi tingkat *engagement* pemelajar secara *real-time*. Pendekatan multimodal diterapkan dengan mengombinasikan data dari *facial emotion*, *eye movements*, dan *head movements* untuk mengklasifikasikan pemelajar sebagai *engaged* atau *disengaged*. Model *deep learning* digunakan untuk *facial emotion recognition*, *blink detection*, dan *head movement tracking*, yang kemudian dihitung menjadi *Engagement Index* (EI). Hasil eksperimen menunjukkan bahwa sistem ini mencapai akurasi sebesar 92.58%.




Gambar II.1 Deteksi *engagement* pemelajar menggunakan FER, kedipan mata, dan gerakan kepala (Gupta dkk., 2023a)

Secara keseluruhan, pendekatan multimodal yang mengintegrasikan analisis emosi wajah dan sikap visual seperti arah kepala atau kondisi mata terbukti lebih unggul dibandingkan metode *unimodal* karena mampu menangkap beragam indikator *non-verbal* secara komprehensif. Dengan menggabungkan berbagai sumber informasi, sistem deteksi *engagement* menjadi lebih akurat, *robust*, dan adaptif terhadap variasi kondisi visual maupun perilaku siswa, sehingga efektivitas pemantauan *engagement* dalam lingkungan pendidikan digital dapat ditingkatkan secara signifikan.


II.4 Facial Emotion Recognition

Facial Expression Recognition (FER) adalah bidang penelitian dalam computer vision dan kecerdasan buatan yang berfokus pada identifikasi dan klasifikasi emosi wajah manusia berdasarkan fitur visual. Teknologi ini memanfaatkan algoritma *machine learning* dan *deep learning* untuk mengenali berbagai emosi seperti bahagia, sedih, marah, terkejut, takut, jijik, dan netral. Proses utama dalam sistem FER mencakup beberapa tahap, yaitu deteksi wajah, ekstraksi fitur, dan klasifikasi emosi (Gambar II.3).



Gambar II.2 Sistem pengenalan emosi wajah

Deteksi wajah dilakukan dengan metode seperti *Haarcascade* (Sukumaran dan Manoharan, 2024) atau MTCNN (Zeng dkk., 2021) untuk menemukan posisi wajah dalam gambar. Setelah wajah terdeteksi, fitur-fitur penting seperti bentuk mata, mulut, dan alis diekstraksi menggunakan teknik seperti *Local Binary Pattern* (LBP) dan *Convolutional Neural Networks* (Sowjanya & Krithiga, 2024). Tahap akhir adalah klasifikasi emosi, yang biasanya dilakukan menggunakan model seperti *Random Forest* (Shobana & Kumar, 2021), atau jaringan saraf dalam seperti ResNet50 (Aly dkk., 2023) dan VGG19 (Gupta dkk., 2023c).



Gambar II.3 Proses utama *facial emotion recognition*

Dalam lingkungan pendidikan daring, FER dapat digunakan untuk menganalisis emosi wajah pelajar guna memahami tingkat *engagement*, kebingungan, atau kejenuhan mereka selama pembelajaran. Dengan menggunakan kamera dan algoritma berbasis *deep learning*, sistem FER dapat mendeteksi emosi pelajar

secara *real-time*, memungkinkan pengajar untuk menyesuaikan metode pengajaran agar lebih interaktif dan efektif. Teknologi ini juga dapat diterapkan dalam sistem *e-learning* adaptif, di mana materi pelajaran secara otomatis disesuaikan berdasarkan respons emosional pemelajar. Selain itu, FER dapat membantu dalam evaluasi pengalaman belajar, dan mendukung pengajar dalam memberikan umpan balik yang lebih personal, serta meningkatkan kualitas interaksi dalam pembelajaran jarak jauh.

Wang, (2021) menyimpulkan bahwa perilaku belajar daring dapat dianalisis secara efektif menggunakan teknik pengenalan emosi berbasis gambar. Proses ini mencakup ekstraksi *keyframe* dari emosi wajah dengan menerapkan *enhanced local binary pattern* (LBP) dan *wavelet transform*. *Keyframe* yang diperoleh digunakan untuk mengekstrak fitur emosi rata-rata untuk mengoptimalkan akurasi dalam *emotion recognition*. Sistem analisis perilaku pembelajaran daring dikembangkan oleh Wang, (2021) adalah dengan mengintegrasikan *face-based emotion recognition methods*. Model klasifikasi emosi pada *image-based daring learning* dirancang menggunakan *attention mechanism*, yang terbukti meningkatkan performa klasifikasi. Hasil penelitiannya menunjukkan bahwa model ini dapat diimplementasikan untuk *daring learning behavior analysis*.

Penerapan FER memiliki tantangan tersendiri terhadap emosi anak (Rathod dkk., 2022). Peneliti Rathod dkk., (2022) menyimpulkan bahwa model *deep learning* efektif untuk deteksi emosi pada anak-anak dalam media pembelajaran daring dengan menggunakan *dataset* LIRIS serta *dataset* khusus yang dikembangkan untuk anak usia 7 hingga 10 tahun. Rathod dkk., (2022) menyatakan bahwa *facial emotion* pada anak-anak berbeda dari orang dewasa, sehingga digunakan 3D 468 *key geometric points* untuk meningkatkan *emotion recognition accuracy* untuk mendeteksi emosi pada anak-anak. Hasil akurasinya mencapai 90.98% melalui *comprehensive comparative analysis* dengan tujuh model arsitektur CNN.

Penerapan FER juga bisa dalam keadaan *real-time* pada video saat pembelajaran daring (Mehta dkk., 2022). Peneliti Mehta dkk., (2022) menyimpulkan bahwa level konsentrasi pemelajar dapat dideteksi secara efektif melalui *real-time facial expression analysis*. Tiga tingkat konsentrasi yang diidentifikasi dan diperoleh dari


facial emotions adalah “*highly concentrated*”, “*nominally concentrated*”, dan “*not concentrated at all*”. Hasil penelitian ini menunjukkan efektivitas model *deep learning*, khususnya VGG16 dalam klasifikasi emosi wajah, dengan akurasi tinggi dalam mendeteksi tingkat konsentrasi. Secara keseluruhan, hasil penelitian mengindikasikan bahwa mengintegrasikan sistem deteksi emosi ke dalam *e-learning systems* dapat meningkatkan pengalaman belajar dengan menyediakan umpan balik secara langsung terkait *engagement* pemelajar.

Meskipun banyak kemajuan telah dicapai, FER masih menghadapi beberapa tantangan, seperti perbedaan budaya dalam emosi (Mattioli & Cabitza, 2024), variasi pencahayaan, serta oklusi atau halangan pada wajah. Salah satu tantangan terbesar adalah menangani wajah yang terhalang oleh tangan, kacamata, atau masker, yang dapat mengurangi akurasi pengenalan emosi wajah (Li dan Deng, 2022).

II.5 Oklusi pada *Facial Emotion Recognition*

Oklusi adalah kondisi dimana suatu objek atau bagian tertentu tertutupi oleh objek lain sehingga tidak terlihat sepenuhnya. Dalam konteks pengenalan emosi wajah, oklusi terjadi ketika bagian wajah tertutup oleh elemen seperti kacamata, masker, tangan, rambut, atau benda lainnya. Dalam banyak kasus, metode pengenalan emosi wajah berbasis *deep learning* mengalami penurunan akurasi ketika menghadapi kondisi oklusi yang signifikan (Wickline dkk., 2025).

Oklusi dapat bersifat parsial atau total, tergantung pada seberapa besar bagian wajah yang tertutup. Oklusi parsial terjadi ketika hanya sebagian kecil wajah yang tertutup, seperti mata yang tertutup kacamata hitam atau mulut yang tertutup masker (Wickline dkk., 2025). Sementara itu, oklusi total dapat terjadi ketika hampir seluruh wajah tertutupi (C. Zhu dkk., 2022). Untuk mengatasi tantangan ini, berbagai teknik seperti augmentasi data, deteksi oklusi, dan rekonstruksi fitur wajah digunakan dalam sistem pengenalan emosi berbasis kecerdasan buatan.



Gambar II.4 (a) Keadaan wajah dengan oklusi *partial* oleh tangan, (b) keadaan wajah dengan oklusi total (Jain & Learned-Miller, 2010)

Untuk mengatasi permasalahan ini, berbagai pendekatan telah dikembangkan, seperti augmentasi data (Malakar dkk., 2024), penggunaan model yang lebih robust terhadap oklusi (Kim & Lee, 2023), serta teknik deteksi dan rekonstruksi wajah (N. Zhang dkk., 2023). Penelitian tentang rekonstruksi wajah lainnya juga pernah dilakukan, seperti yang dilakukan oleh K. Zhu dkk., (2023). Mereka melakukan rekonstruksi wajah dalam bentuk 3D. Menghapus objek oklusi di wajah dan menggunakan *template* (database bagian-bagian wajah) dalam bentuk 3D, berbagai jenis path wajah sebagai media untuk mengenerate (mengisi) bagian oklusi yang dihapus. Penelitian ini berhasil menghapus dan menggenerate wajah oklusi menjadi wajah tanpa oklusi, namun sayangnya tidak ada pengujian lebih lanjut terhadap nilai akurasi klasifikasi emosi wajah. Walaupun demikian metode yang dilakukan Kaifeng Zhu dkk, bisa dijadikan referensi dalam hal pendekatan yang tepat dalam menghapus oklusi pada wajah.


Ada cara lain untuk mengatasi oklusi pada wajah yaitu pada bagian *pre-processing* Peneliti Cao dkk., (2021) mencoba untuk mengenali emosi dari wajah yang *non-frontal* dengan berbasis gambar 3D. Mereka melakukannya dengan mengambil setengah bagian wajah dan menggabungkannya dalam bentuk 3D kemudian melakukan penguatan bentuk otot disekitar hidung untuk dapat meningkatkan akurasi pengenalan emosi dari wajah 3D. Hasilnya ada kenaikan akurasi terhadap beberapa emosi dasar setelah melakukan proses penguatan otot muka disekitar hidung.

Walaupun bentuk data wajah dalam 3D dapat mengandung lebih banyak informasi dan meningkatkan akurasi pengenalan emosi wajah (Cao dkk., 2021), namun mengubah gambar 2D ke bentuk 3D dapat merubah informasi asli dari data wajahnya seperti bentuk otot muka yang tidak sesuai dengan data aslinya. Data


gambar dalam bentuk 3D juga memiliki kompleksitas komputasi yang lebih tinggi gambar 2D sehingga memerlukan waktu proses yang lebih lama dari gambar 2D (Morar dkk., 2017). Apa yang dilakukan oleh Cao dkk., (2021) tersebut dijadikan dasar berpikir dalam penelitian untuk mengusulkan sebuah metode yang sama namun dalam bentuk gambar 2D dengan tujuan metode hasil penelitian ini dapat tetap dijalankan dengan optimal pada perangkat dengan spesifikasi yang rendah.

II.6 *Mind Map* Alternatif Solusi Deteksi Emosi

Berdasarkan beberapa literatur yang telah dibahas, dipetakan referensi penelitian terdahulu beserta tantangannya yang berkaitan dengan pilihan-pilihan yang ada untuk mendeteksi emosi pemelajar pada pembelajaran daring, hasilnya dapat dilihat pada Gambar II.5. Selain itu, dibuat juga *mind map* tentang penelitian yang sudah dilakukan untuk mengatasi masalah wajah yang teroklusi dalam penerapan FER pada Gambar II.6.




Gambar II.5 *Mind map* deteksi emosi pemelajar pada media pembelajaran daring



Gambar II.6 *Mind map* tentang cara mengatasi masalah oklusi pada FER

II.7 Peta Literatur


Peta literatur disusun untuk memberikan gambaran mendasar mengenai komponen-komponen maupun dasar yang diperlukan dalam membangun sistem deteksi *engagement* pemelajar dalam pembelajaran daring.



Gambar II.7 Peta literatur deteksi *engagement* pada pembelajaran daring

BAB III Metodologi Penelitian

Semua metodologi yang akan digunakan dalam penelitian dibahas dalam bab ini. Gambar III.1 menunjukkan tahapan penelitian *Design Science Research Methodology* (DSRM) yang akan diterapkan dalam penelitian ini.



Gambar III.1 *Design Science Research Methodology*

Gambar III.1 menunjukkan bahwa DSRM terdiri dari enam tahapan penelitian: identifikasi masalah, definisi tujuan dan solusi, perancangan dan pengembangan, demonstrasi, evaluasi, dan komunikasi. Subbab berikutnya memberikan penjelasan tentang setiap langkah yang harus dilakukan.

III.1 Identifikasi Masalah dan Motivasi

Pada tahap identifikasi masalah dan motivasi, fokus akan berada pada identifikasi masalah dan motivasi untuk melakukan penelitian. Tabel III.1 menunjukkan langkah-langkah *input*, proses, dan *output* pada tahap identifikasi masalah dan motivasi.

Tabel III.1 Tahap identifikasi masalah dan motivasi

<i>Input</i>	- Riset penelitian - Dokumen ilmiah
Proses	Kajian literatur
<i>Output</i>	- Informasi mekanisme deteksi <i>engagement</i> pemelajar pada media pembelajaran daring - Alasan pemilihan FER sebagai pendekatan umpan balik pada pembelajaran daring

Berdasarkan Tabel III.1, *input* dari tahap identifikasi adalah berupa riset penelitian dan dokumen ilmiah yang relevan dengan bidang pengenalan emosi wajah serta analisis perilaku dalam konteks pembelajaran daring. Sumber-sumber tersebut dipilih secara sistematis untuk memastikan dasar untuk memilih metode dan teknis

yang diperlukan, sehingga dapat memberikan landasan yang kuat bagi pemetaan literatur mengenai deteksi *engagement* pelajar.

Melalui proses kajian literatur, penelitian ini menelaah berbagai pendekatan yang telah dikembangkan, termasuk metode berbasis CNN, DeepFace, FaceLib, dan SVM, serta pemanfaatan pustaka MediaPipe untuk analisis visual. Proses ini tidak hanya menyoroti keunggulan dan keterbatasan masing-masing metode, tetapi juga mengaitkannya dengan karakteristik pembelajaran daring yang menuntut pemantauan *engagement* pelajar secara lebih adaptif dan *real-time*.

Output dari proses ini adalah menghasilkan informasi komprehensif mengenai mekanisme deteksi *engagement* pelajar pada media pembelajaran daring, sekaligus memberikan alasan konseptual dan empiris atas pemilihan FER sebagai pendekatan untuk mendeteksi emosi. FER dipandang mampu menjembatani aspek perilaku, kognisi, dan afeksi mahasiswa, sehingga dapat digunakan sebagai indikator *engagement* yang lebih akurat

III.2 Definisi Tujuan dan Solusi

Fokus tahap kedua DSRM adalah mendefinisikan tujuan dan solusi berdasarkan masalah yang telah diidentifikasi sebelumnya. Identifikasi tujuan penelitian kemudian memberikan solusi untuk mengatasi masalah yang ada. Pada tahap tujuan dan solusi, Tabel III.2 menunjukkan tahapan *input*, proses, dan *output*.

Tabel III.2 Tahap tujuan dan solusi

<i>Input</i>	- Informasi mekanisme deteksi <i>engagement</i> pelajar pada pembelajaran daring - Alasan pemilihan FER sebagai pendekatan deteksi emosi pada pembelajaran daring
Proses	- Eksplorasi cara untuk menangani keadaan oklusi pada FER - Eksplorasi model FER yang tersedia dan sesuai
<i>Output</i>	Rancangan solusi

Berdasarkan hasil identifikasi masalah dan penelusuran motivasi penelitian, langkah berikutnya yang dilakukan adalah eksplorasi mendalam terkait penanganan kondisi oklusi pada sistem FER, serta evaluasi terhadap model-model FER yang tersedia. Tahapan ini diawali dengan pengumpulan informasi mengenai mekanisme umpan balik pada pembelajaran daring, serta analisis alasan pemilihan pendekatan

FER sebagai metode utama dalam penyediaan umpan balik. Selanjutnya, dilakukan eksplorasi berbagai metode penanganan oklusi pada wajah yang telah diulas pada studi literatur, yang mencakup pendekatan pada tahap pre-processing maupun modifikasi pada arsitektur model klasifikasi.

Melalui kajian literatur tersebut, diperoleh beberapa alternatif solusi dalam menangani pengaruh oklusi terhadap akurasi pengenalan emosi wajah. Penelitian ini memilih untuk mengimplementasikan improvisasi pada bagian pre-processing data, dengan pertimbangan bahwa pendekatan ini diharapkan mampu meningkatkan kinerja sistem tanpa menimbulkan peningkatan beban komputasi yang signifikan. Implikasi dari pemilihan strategi tersebut adalah terciptanya rancangan solusi yang lebih efisien dan dapat diintegrasikan ke dalam sistem pembelajaran daring berbasis pengenalan emosi wajah secara lebih praktis dan optimal.

III.3 Perancangan dan Pengembangan

Tahap ketiga dalam DSRM adalah mendefinisikan perancangan dan pengembangan berdasarkan rancangan solusi yang telah didefinisikan sebelumnya. Pada tahap ini akan berfokus pada pengembangan metode *pre-processing* untuk mengatasi masalah oklusi wajah oleh tangan pada penerapan FER di media pembelajaran daring. Tabel III.3 merupakan tahapan *input*, proses, dan *output* pada tahap perancangan dan pengembangan.

Tabel III.3 Tahap perancangan dan pengembangan

<i>Input</i>	Rancangan solusi
Proses	- Pengembangan metode <i>pre-processing</i> untuk mengatasi masalah oklusi wajah oleh tangan pada penerapan FER di LMS - Pengembangan aplikasi LMS dengan fokus pada fitur <i>pembelajaran asinkron</i> - Implementasi metode usulan pada aplikasi LMS
<i>Output</i>	Aplikasi LMS dengan fitur FER

Berdasarkan Tabel III.3, tahapan perancangan dan pengembangan pada penelitian ini diawali dengan pemanfaatan rancangan solusi yang telah diidentifikasi pada tahap sebelumnya sebagai *input* utama. Pada fase ini, fokus diarahkan pada pengembangan metode *pre-processing* yang secara khusus ditujukan untuk

mengatasi permasalahan oklusi wajah oleh tangan dalam implementasi FER pada aplikasi media pembelajaran daring.

Proses pengembangan meliputi perancangan dan penerapan teknik *pre-processing* data citra yang mampu mendeteksi dan memitigasi dampak oklusi, sehingga kualitas fitur emosi wajah yang diekstraksi dapat tetap optimal meskipun terdapat hambatan visual. Selain itu, penelitian ini turut mengembangkan aplikasi media pembelajaran daring dengan penekanan pada fitur *pembelajaran asinkron*, serta melakukan implementasi metode usulan secara terintegrasi ke dalam aplikasi tersebut.

Output dari tahapan ini adalah terciptanya aplikasi pembelajaran daring yang dilengkapi dengan fitur pengenalan emosi wajah, sehingga dapat memberikan *insight* yang lebih mendalam terkait *engagement* pemelajar dalam proses pembelajaran daring secara komprehensif.

III.4 Demonstrasi

Tahap keempat dalam metodologi DSRM adalah demonstrasi. Pada tahap ini akan berfokus pada uji coba terhadap konsep yang telah dikembangkan. Pada Tabel III.4 merupakan *input*, proses, dan *output* pada tahap demonstrasi.

Tabel III.4 Tahapan demonstrasi

<i>Input</i>	Wajah pemelajar
Proses	Mengakses materi pembelajaran asinkron
<i>Output</i>	Data <i>engagement</i> pemelajar

Berdasarkan Tabel III.4, tahapan demonstrasi dalam penelitian ini menggunakan wajah pemelajar sebagai *input* utama, dimana metode *pre-processing* yang telah dikembangkan pada fase perancangan dan pengembangan diimplementasikan pada data nyata. Pada tahap ini, dilakukan proses pengujian dengan memanfaatkan aplikasi pembelajaran daring pada fitur pembelajaran asinkron yang telah dilengkapi fitur pengenalan emosi wajah. Setiap peserta pembelajaran mengakses materi secara mandiri, sementara sistem secara otomatis melakukan analisis emosi wajah, arah kepala, dan kondisi mata untuk memperoleh indikator *engagement* pemelajar.

Output dari tahapan demonstrasi berupa data *engagement* pemelajar yang dihasilkan dari proses analisis multimodal tersebut. Data *engagement* yang diperoleh dapat dikaji lebih lanjut oleh pengajar sehingga dapat digunakan sebagai dasar untuk melakukan evaluasi dan improvisasi materi pembelajaran daring yang lebih efektif dan personal. Dengan demikian, tahapan ini berfungsi sebagai validasi atas implementasi metode dan sebagai penghubung antara teknologi yang dikembangkan dengan kebutuhan nyata dalam peningkatan kualitas pembelajaran daring.

III.5 Evaluasi

Tahap kelima dari DSRM yaitu tahap evaluasi. Pada tahap ini akan berfokus pada pengukuran performa dari model yang telah dikembangkan. Pada Tabel III.5 merupakan tahapan *input*, proses, dan *output* pada tahap evaluasi.

Tabel III.5 Tahap evaluasi

<i>Input</i>	- Data wajah dengan oklusi tangan (<i>baseline</i>) - Data wajah setelah penerapan <i>pre-processing</i> (metode usulan)
Proses	Pengukuran akurasi pada data <i>baseline</i> dan hasil metode usulan
<i>Output</i>	Persentase pengaruh terhadap probabilitas emosi wajah pemelajar setelah menerapkan metode usulan

Berdasarkan Tabel III.5, tahap evaluasi dalam penelitian ini menjadikan data wajah dengan oklusi tangan sebagai *baseline*, dan data wajah yang telah melalui tahap *pre-processing* menggunakan metode usulan sebagai *input* utama. Proses evaluasi dilakukan dengan mengukur tingkat akurasi pengenalan emosi pada kedua jenis data tersebut, yakni sebelum dan sesudah penerapan metode *pre-processing* yang dikembangkan.

Tahapan evaluasi ini bertujuan untuk memperoleh gambaran yang jelas mengenai efektivitas metode usulan dalam meningkatkan probabilitas deteksi emosi wajah pemelajar, khususnya pada kondisi oklusi tangan yang sering kali menjadi hambatan dalam sistem FER. Proses perbandingan dilakukan secara sistematis dengan menganalisis distribusi probabilitas emosi wajah pada data *baseline* dan data hasil *pre-processing* menggunakan empat model, yaitu CNN, DeepFace, FaceLib, dan SVM sehingga dapat diidentifikasi persentase perubahan dan tingkat perbaikan yang dihasilkan masing-masing model.

Output dari tahap evaluasi ini berupa persentase pengaruh metode *pre-processing* terhadap peningkatan akurasi serta probabilitas deteksi emosi wajah pemelajar. Temuan tersebut menjadi indikator keberhasilan metode yang diusulkan dan memberikan dasar empiris yang kuat bagi pengembangan lebih lanjut sistem FER pada lingkungan pembelajaran daring.

III.6 Komunikasi

Tahap terakhir dalam DSRM adalah komunikasi. Pada tahap ini akan berfokus pada dokumentasi hasil yang kemudian dikomunikasikan dalam bentuk tulisan ilmiah. Tabel III.6 merupakan tahapan *input*, proses, dan *output* pada tahap komunikasi.

Tabel III.6 Tahap komunikasi

<i>Input</i>	- Rancangan solusi - Metode <i>pre-processing</i> (metode usulan) - Hasil evaluasi perubahan probabilitas emosi sebelum dan sesudah menerapkan metode usulan
Proses	Penyusunan dokumen ilmiah
<i>Output</i>	- Tesis - Artikel ilmiah

Berdasarkan Tabel III.6, tahap komunikasi dalam penelitian ini menggunakan hasil-hasil dari seluruh rangkaian proses sebelumnya sebagai *input*, meliputi rancangan solusi, metode *pre-processing* (metode usulan), serta hasil evaluasi perubahan probabilitas emosi sebelum dan sesudah penerapan metode tersebut. Pada tahap ini, proses utama yang dilakukan adalah penyusunan dokumen ilmiah sebagai bentuk komunikasi dan diseminasi hasil penelitian.


Dalam proses komunikasi ini, dilakukan dengan merangkum dan mengintegrasikan seluruh temuan dan analisis yang telah dilakukan ke dalam bentuk dokumen tesis yang sistematis, serta menyusun artikel ilmiah untuk dipublikasikan pada jurnal bereputasi. *Output* dari tahap komunikasi adalah dokumen tesis dan artikel ilmiah yang dapat digunakan sebagai referensi oleh peneliti lain, pengembang teknologi pendidikan, maupun praktisi di bidang pembelajaran daring. Upaya ini bertujuan untuk memperkaya literatur tentang penerapan FER dalam penilaian engagement pemelajar, sekaligus mendorong pemanfaatan hasil penelitian secara lebih luas pada praktik pendidikan berbasis teknologi.

BAB IV Analisis dan Desain

Bagian ini akan menjelaskan gambaran penelitian yang akan dilakukan. Pada bagian ini juga akan dijelaskan lingkungan yang akan di analisis dan kondisi-kondisi kapan FER akan digunakan untuk menentukan *engagement* dari pemelajar.

IV.1 Lingkungan Penerapan

Lingkungan penerapan penelitian ini adalah lingkungan pembelajaran daring dengan memanfaatkan *platform learning management system*. Lalu, kondisi penerapan *facial emotion recognition* pada *learning management system* adalah khusus pada kondisi pembelajaran asinkron yang mewajibkan pemelajar untuk menonton video rekaman pembelajaran yang diberikan oleh pemateri seperti apa yang tertera pada Gambar IV.1.



Gambar IV.1 Alur penerapan mekanisme umpan balik pada LMS

IV.2 Analisis Kebutuhan Sistem

Dalam analisis kebutuhan sistem ini, akan dibahas secara mendalam mengenai kebutuhan fungsional, non-fungsional, serta kebutuhan pengguna yang mendasari integrasi metode usulan dengan *learning management system* (LMS), guna

memastikan pemantauan emosi pemelajar yang efektif dan memberikan umpan balik yang konstruktif bagi pengajar dalam proses pembelajaran asinkron.

IV.2.1 Kebutuhan Fungsional

Kebutuhan fungsional sistem ini mencakup serangkaian fitur dan fungsi yang harus ada untuk memastikan sistem dapat berjalan sesuai dengan tujuan yang diinginkan, mendukung proses operasional, dan memberikan hasil yang diharapkan. Adapun kebutuhan fungsional dari sistem yang akan dibuat adalah:

1. Pengenalan emosi wajah (FER), dimana sistem harus dapat mengenali emosi wajah pemelajar bahkan ketika wajah tertutup sebagian oleh tangan atau miring dengan penerapan metode yang memanfaatkan setengah bagian wajah yang kemudian digabungkan untuk membentuk wajah yang seolah-olah menghadap ke depan.
2. Integrasi dengan *learning management system* (LMS), yaitu sistem FER harus terintegrasi dengan aplikasi LMS yang digunakan untuk pembelajaran daring yang memungkinkan pemantauan emosi tepat setelah sesi pembelajaran berakhir dan memberikan umpan balik kepada pengajar.
3. Kesimpulan *engagement*, berdasarkan hasil dari FER, sistem harus dapat memberikan analisis *engagement* pemelajar, yang dapat digunakan oleh pengajar untuk menilai seberapa baik tingkat *engagement* pemelajar dalam pembelajaran daring.
4. Umpan balik, dimana sistem harus mampu memberikan umpan balik kepada pengajar berdasarkan data pemelajar tentang tingkat *engagement* dari data hasil analisis emosi yang dilakukan.

IV.2.2 Kebutuhan Non-Fungsional

Kebutuhan non-fungsional sistem ini mencakup aspek-aspek yang mendukung kinerja dan kualitas pengalaman pengguna. Dalam konteks sistem yang akan dikembangkan, kebutuhan non-fungsional tersebut berfokus pada akurasi dan keandalan, dimana sistem dituntut memiliki kemampuan mendeteksi serta mengidentifikasi emosi wajah, bahkan pada kondisi wajah yang tertutup sebagian

atau *non-frontal*. Selain itu, kinerja sistem harus konsisten dan dapat diandalkan dalam berbagai variasi posisi wajah

IV.2.3 Kebutuhan Pengguna

Kebutuhan pengguna sistem ini mencakup kemampuan bagi pemelajar untuk menggunakan aplikasi dengan mudah dalam memantau emosi wajah mereka selama pembelajaran daring, bagi pengajar untuk mengakses analisis emosi dan tingkat *engagement* pemelajar secara *real-time*, serta bagi administrator untuk mengelola dan memelihara sistem secara efisien, memastikan integrasi yang lancar dengan platform pembelajaran yang ada. Adapun kebutuhan pengguna pada sistem yang dibuat antara lain:

1. Pemelajar harus dapat menggunakan aplikasi LMS dengan mudah, dimana aplikasi secara otomatis memonitor emosi wajah mereka selama sesi pembelajaran dan memberikan umpan balik mengenai tingkat *engagement* mereka.
2. Pengajar harus dapat melihat analisis emosi dan *engagement* pemelajar dalam bentuk yang mudah dipahami, untuk dapat membuat penyesuaian pada pendekatan pengajaran mereka. Mereka juga harus dapat mengakses statistik yang menunjukkan pola *engagement* pemelajar selama sesi pembelajaran.

IV.2.4 Kebutuhan Perangkat Keras dan Perangkat Lunak

Sistem harus dapat berjalan dengan baik pada perangkat keras umum yang digunakan pemelajar dan pengajar, seperti komputer dengan spesifikasi kamera yang cukup untuk mendeteksi emosi wajah.

Dari sisi perangkat lunak, sistem harus berbasis pada perangkat lunak yang mendukung pengenalan emosi wajah menggunakan teknik *computer vision* dan *machine learning* dan juga harus *cross platform*, sehingga tidak perlu melakukan pengaturan yang memberatkan pengguna.

IV.3 Justifikasi Solusi

Berdasarkan tinjauan literatur yang sudah dilakukan, ada beberapa alternatif solusi yang bisa dilakukan dalam menyelesaikan permasalahan penelitian. Adapun analisisnya dijabarkan dalam Tabel IV.1.

Tabel IV.1 Alternatif solusi untuk deteksi emosi pemelajar

Modalitas	Metode	Kelebihan	Kekurangan
Visual	Pengenalan Emosi Wajah	Model dan <i>dataset</i> publik sudah banyak, mudah untuk didapatkan dan dimodifikasi, pemrosesan relatif lebih ringan	Akurasi turun pada data wajah yang teroklusi
Audio	Pengenalan Emosi Suara	Akurasi pengenalan emosi baik	Beban komputasi sedikit lebih berat
Teks	Analisis Sentimen	Beban komputasi ringan karena hanya memproses teks	Hanya bisa menentukan emosi positif dan negatif, juga seringkali muncul emosi palsu dalam tulisan
Sinyal Tubuh	Jam Tangan Pintar atau perangkat Sensor	Akurasi lebih akurat	Memerlukan <i>resources</i> yang banyak dan tidak murah
Multi-Modal	FER + Analisis Sentimen	Akurasi lebih akurat	Beban komputasi bisa bertambah sehingga bisa menambah waktu pemrosesan

Dihubungkan dengan analisis kebutuhan sistem pada sub bab IV.2, pemilihan modalitas yang tepat untuk dijadikan solusi penelitian adalah modalitas visual dengan metode pengenalan emosi wajah yang mana pemrosesannya bisa lebih ringan dan murah dibandingkan dengan modalitas lain dengan tetap menjaga akurasi pengenalan emosinya.

Untuk memenuhi kebutuhan minimal perangkat keras dan perangkat lunak sistem sesuai dengan penjelasan pada sub bab IV.2.4, sistem akan dibuat dengan berbasis web menggunakan *flask* yaitu *python* sebagai *back-end* dan *html+css+js* sebagai *front-end*. Penggunaan *flask* akan memudahkan integrasi antara *front-end* dan *back-end* dan bisa diakses melalui sebuah aplikasi *browser* sehingga pengguna tidak perlu melakukan pengaturan apapun dalam menggunakannya.


IV.4 Analisis Wajah

Ada beberapa parameter untuk menentukan *engagement* pemelajar, pertama adalah arah kepala (*head pose*), lalu arah pandangan mata (*eye gaze*), dan emosi wajah. Sebagai contoh, Gambar IV.2 memperlihatkan hasil analisis wajah menggunakan tiga parameter yang digunakan (mata, kepala, emosi) dari sebuah proses ekstraksi wajah baik yang bisa berasal dari gambar maupun video.



Gambar IV.2 Contoh hasil analisis wajah dengan paramater arah pandangan mata, arah kepala, dan emosi wajah

Adapun penggunaan pendekatan FER tidak selalu pada setiap gambar yang di eksekusi, contoh: jika kondisi kepala dan mata sedang menatap ke samping (tidak melihat layar minitor) seperti pada Gambar IV.3, maka sistem akan langsung menyimpulkan bahwa pemelajar tersebut dalam keadaan tidak fokus tanpa harus dilakukan proses pengenalan emosi wajah.



Gambar IV.3 Contoh kondisi wajah yang arah kepala dan mata tidak menghadap monitor atau menghadap kesamping (gambar dibuat dengan AI)

IV.5 Desain Solusi

Bagian ini akan membahas tentang desain solusi yang diperlukan untuk membuat keseluruhan sistem mulai dari desain solusi umum, desain metode usulan, desain tampilan antarmuka, hingga desain pengujian dalam penelitian ini.


IV.5.1 Desain Solusi Umum

Adapun gambaran umum desain keseluruhan sistem yang dibuat dapat dilihat pada Gambar IV.4.



Gambar IV.4 Gambaran umum ajuan solusi sistem


Proses teknis dari ajuan penelitian ini mulai dari proses deteksi wajah, *pre-processing*, klasifikasi emosi oleh model FER, analisis *engagement*, dan keluaran akhirnya berupa kesimpulan *engagement* pemelajar. Walaupun keseluruhan sistem akan dibuat sesuai dengan Gambar IV.4, namun fokus penelitian ini hanya pada bagian *pre-processing* saja, sehingga pengujiannya juga akan berfokus pada implikasi yang dihasilkan dari metode usulan pada bagian *pre-processing*. Adapun detail teknis yang menjadi fokus penelitian ini dijelaskan pada Gambar IV.5.



Gambar IV.5 Detail teknis dan fokus penelitian pada bagian *pre-processing*

IV.5.2 Desain Algoritma Program

Pengenalan emosi wajah hanya diterapkan ketika mata dan kepala masih terdeteksi dalam keadaan melihat monitor. Lebih lengkapnya desain algoritma untuk menentukan *engagement* pemelajar dapat dilihat pada diagram alir Gambar IV.6.



Gambar IV.6 Diagram alir algoritma kondisi penggunaan FER untuk menentukan *engagement* pemelajar


Penjelasan diagram alir pada Gambar IV.6 adalah sebagai berikut:

1. Video rekaman wajah pemelajar diekstrak dan diproses satu *frame* per detik.
2. Kumpulan *frame* tersebut diproses satu per satu selama panjang video untuk dianalisis.
3. Proses pertama pada satu *frame* adalah dengan melakukan deteksi wajah.
4. Data wajah yang selanjutnya dilakukan proses deteksi arah mata, arah kepala melihat, dan deteksi emosi dengan FER, yang masing-masing

hasilnya akan diberikan bobot sesuai dengan literatur (Sukumaran & Manoharan, 2024).

5. Bobot ketika kepala atau arah pandangan melihat lurus ke layar adalah 1, dan ketika tidak melihat lurus ke layar maka bobotnya 0.
6. Bobot ketika mata terbuka adalah 2.5, dan ketika tertutup adalah 0.
7. Bobot emosinya antara lain *angry* 0.1, *disgust* 0.9, *fear* 0.5, *happy* 1.1, *neutral* 1.4, *sad* 0.3, *surprised* 0.7.
8. Bobot pada poin 5, 6, dan 7 dijumlahkan, total hasilnya (EI) akan diklasifikasikan menjadi *engagement status* dari pemelajar dengan aturan jika EI lebih besar sama dengan 4.5 maka statusnya adalah **highly engagement**, jika EI lebih kecil dari 4.5 dan lebih besar sama dengan 4 maka statusnya adalah **confused**, jika EI lebih kecil dari 4 dan lebih besar sama dengan 2.5 maka statusnya adalah **boredom**, jika EI lebih kecil dari 2.5 dan lebih besar dari 0 maka statusnya **sleepy**, dan jika EI sama dengan 0 maka statusnya **very not engaged**.
9. Proses akan diiterasi sebanyak frame yang tersedia hasil dari proses pada poin 1.
10. Ketika semua *frame* sudah diproses maka proses terakhir adalah menganalisis seluruh data *engagement index* menggunakan LLM untuk mendapatkan kesimpulan akhir dan *insight* yang berupa analisis *engagement* pemelajar juga sedikit saran perbaikan atas materi yang diberikan oleh pengajar, dan proses selesai.

Hasil akhir dari seluruh proses tersebut akan disajikan dalam bentuk grafik, sehingga memudahkan untuk melakukan analisis mendalam terhadap masing-masing hasil dari pemelajar.



Gambar IV.7 Skema metode usulan dalam penanganan masalah oklusi dan wajah *non-frontal* pada wajah

Penjelasan pada gambar IV.7 adalah sebagai berikut:

1. Proses dimulai dari gambar *input* yang akan dilakukan proses deteksi wajah, jika wajah tidak terdeteksi maka proses langsung akan selesai, dan jika wajah terdeteksi maka akan dilanjutkan pada proses selanjutnya.
2. Selanjutnya akan dilakukan penyesuaian arah *roll* kepala, sehingga kepala yang miring akan dibuat tegak lurus.
3. Proses selanjutnya adalah deteksi tangan, jika ada tangan terdeteksi maka akan dilakukan *landmarking* pada objek tangan dan wajah, namun jika tidak ada tangan yang terdeteksi maka *landmarking* hanya dilakukan pada objek wajah saja.
4. Hasil *landmarking* selanjutnya akan dilakukan *masking* untuk membentuk objek, wajah diakan dibuat objek dengan warna putih, dan tangan akan dibuat objek berwarna merah.

5. Gambar objek yang hanya wajah saja maupun yang merupakan gabungan objek tangan dan wajah selanjutnya akan dibagi dua berdasarkan titik tengah wajah, sehingga menghasilkan bagian wajah kiri dan wajah kanan.
6. Selanjutnya adalah proses memilih bagian gambar wajah kiri ataupun kanan. Jika objeknya hanya wajah, maka proses pemilihannya adalah dengan memilih luas *pixel* putih yang lebih besar, namun jika objeknya merupakan gabungan wajah dan tangan, maka proses pemilihannya adalah bagian yang memiliki *pixel* merah yang lebih sedikit ataupun bagian yang tidak memiliki *pixel* merah sama sekali.
7. Bagian gambar wajah yang terpilih dilakukan proses *flip* dan *combine* sehingga hasilnya akan membentuk wajah yang seolah menghadap ke depan dan tanpa adanya oklusi tangan.
8. Proses selesai.

Wajah dari hasil metode usulan akan dilakukan proses FER sesuai dengan skema pada Gambar IV.7 dengan memanfaatkan model FER yang sudah ada untuk mendapatkan data emosi wajah dari pemelajar. Hasil data emosi wajah pemelajar akan digabungkan dengan data arah pandangan mata dan data arah kepala menghadap untuk disimpulkan *engagement* dari pemelajar yang melakukan pembelajaran daring secara asinkron dengan materi video.


IV.6 Desain Pengujian

Pengujian akan dilakukan dengan membandingkan akurasi pengenalan emosi wajah pada wajah yang tanpa dilakukan *pre-processing* dengan metode usulan dan data wajah yang dilakukan *pre-processing* dengan metode usulan. Hal tersebut untuk mendapatkan seberapa besar pengaruh dari metode yang diusulkan dalam meningkatkan akurasi pada wajah yang teroklusi. Adapun langkah-langkah pengujiannya adalah sebagai berikut :

1. Mengumpulkan *dataset* publik FER yang tersedia.
2. Membersihkan *dataset* yang terkumpul seperti menghapus gambar yang tidak sesuai dengan label emosinya dengan menggunakan tools *py-feat* (Cheong dkk., 2023).

3. Memisahkan data wajah yang lurus dan kondisi *non-frontal*.
4. Data wajah lurus yang sudah bersih kemudian dilakukan augmentasi berupa penambahan objek tangan sintesis pada sebagian wajah dan hasilnya dilabeli dengan “*Dataset Before*”.
5. “*Dataset Before*” lalu dilakukan proses dengan metode usulan, dan hasilnya akan dilabeli dengan “*Dataset After*”.
6. “*Dataset Before*” dan “*Dataset After*” pada poin 5 masing-masing akan dilakukan pengujian akurasi dengan 4 model yaitu CNN, DeepFace, Facelib, dan SVM.
7. Hasil akurasi pada “*Dataset Before*” dan “*Dataset After*” akan dibandingkan dan dihitung selisihnya untuk melihat pengaruh terhadap probabilitas emosi.
8. Hasil akurasi juga akan diuji per kelas emosi, sehingga tampak emosi mana yang paling berdampak setelah dilakukan pemrosesan dengan metode usulan.

Dataset yang akan digunakan dalam pengujian adalah *dataset* FER publik gabungan dari Affectnet (Mollahosseini dkk., 2019) dan RafDb (Li dkk., 2017). Untuk memenuhi kebutuhan data wajah yang tertutup tangan, maka data wajah lurus yang diseleksi dari gabungan *dataset* tersebut akan dilakukan proses penambahan tangan sintesis, hasilnya merupakan representasi kemungkinan terburuk pada kondisi wajah tertutup sebagian oleh tangan (vertikal). Adapun prosesnya dapat dilihat pada Gambar IV.8.



Gambar IV.8 Proses penambahan tangan sintesis, (a) gambar asli, (b) tangan sintesis, (c) hasil augmentasi

Pada akhirnya data wajah yang akan digunakan dalam pengujian ini adalah data wajah yang teroklusi dengan tangan sebagian, dan data wajah yang miring (*non-frontal*) sesuai dengan Gambar IV.9.



Gambar IV.9 Data wajah untuk pengujian, (a) wajah dengan oklusi tangan, (b) wajah non-frontal

IV.7 Pengembangan

Sistem keseluruhan akan dibuat dengan berbasis aplikasi web. Menggunakan *flask* sebagai *back-end* dan *html css js* sebagai *front-end* untuk mendukung sistem yang bisa diakses dengan *cross-platform*.

IV.7.1 Perangkat Keras

Penelitian ini menggunakan laptop dengan prosesor Intel(R) Core(TM) i3-7020U 2.30 GHz (4 Core) dan RAM 8 GB. Meskipun tergolong spesifikasi rendah dibanding standar komputasi modern, perangkat ini masih memadai untuk mendukung tugas pemrosesan citra dasar. Pemilihan perangkat keras tersebut juga mencerminkan penyesuaian kebutuhan penelitian dengan keterbatasan sumber daya komputasi, sekaligus menegaskan bahwa sistem yang dirancang dapat diimplementasikan pada lingkungan dengan kapasitas komputasi menengah ke bawah.


IV.7.2 Perangkat Lunak

Perangkat lunak yang digunakan dalam pengembangan sistem antara lain, sistem operasi Windows 10, aplikasi VSCode untuk melakukan programming, dan Jupyter Notebook untuk melakukan analisis hasil. Python dengan *library* Flask digunakan sebagai *back-end* karena kemampuannya dalam mengintegrasikan *python* dengan tugas pemrosesan *computer vision* dan *html-css-js* sebagai media yang bertugas sebagai *interface* sistem. *Database* yang digunakan adalah *mysql*, karena data pada

sistem ini terstruktur sehingga *mysql* dinilai cukup untuk melakukan tugasnya dengan baik.

IV.7.2.1 Desain Halaman *Login*

Halaman login dibuat dengan tampilan yang sederhana dan mudah digunakan, sehingga pengguna dapat mengakses sistem tanpa kesulitan. Penempatan elemen seperti kolom *username*, *password*, serta tombol masuk diatur secara jelas untuk memudahkan proses autentikasi. Adapun hasil rancangan halaman *login* pada penelitian ini dapat dilihat pada Gambar IV.10.

A wireframe of a login form titled "Login Form". It features two input fields labeled "Username" and "Password", each with a "Placeholder" text inside. Below the password field are two buttons, both labeled "Button". The form is centered on a light gray background with faint circular patterns.

Gambar IV.10 Rancangan desain halaman *login*

IV.7.2.2 Desain Halaman Pembelajaran Asinkron


Halaman pembelajaran asinkron akan berisi beberapa elemen, yaitu *frame* video pembelajaran, *frame* tampilan dari *webcam*, dan tombol navigasi untuk memulai dan menyelesaikan video pembelajaran. Adapun hasil rancangan halaman pembelajaran asinkron pada penelitian ini dapat dilihat pada Gambar IV.11.

A wireframe of an asynchronous learning page. It has a header "LMS" and a user profile icon. A left sidebar contains a menu with "Home", "Akademik", "Matakuliah", and "Sign out". The main content area is titled "Video Pembelajaran" and contains a large video player with a placeholder image. To the right of the video player is a "Video Webcam" section with a webcam icon, a "Play / Pause" button, and a status display showing "Face detected : true/false" and "Emotion : -".

Gambar IV.11 Rancangan halaman pembelajaran asinkron

IV.7.2.3 Desain Halaman Data *Engagement*


Halaman ini akan berisi data berupa grafik tentang analisis emosi pemelajar berdasarkan hasil dari penilaian sistem saat pemelajar sedang mengakses materi pada pembelajaran asinkron. Pada bagian ini akan ditampilkan visualisasi tingkat *engagement*, emosi dominan, hingga masukan umpan balik kepada pengajar terhadap materi yang diberikan. Adapun hasil rancangan halaman analisis emosi pada penelitian ini dapat dilihat pada Gambar IV.12.



Gambar IV.12 Rancangan halaman data *engagement*

IV.7.3 Pengembangan Metode Usulan

Gambar yang akan diproses adalah hasil tangkapan kamera yang dilakukan pada pihak *front-end*. Gambar tersebut akan dikirim ke *back-end* melalui *socket io*, lalu dilakukan *pre-processing* terlebih dahulu dengan metode usulan. Adapun langkah pada metode usulan ini dapat dilihat pada Gambar IV.13.



Gambar IV.13 Langkah pada metode usulan


Pada Gambar IV.13 dapat dijelaskan bahwa gambar yang berupa wajah yang teroklusi objek tangan akan dilakukan konversi ke bentuk *mesh* dengan memanfaatkan *library mediapipe*. Lalu gambar tersebut akan dikoreksi arah kepalanya (*roll*) yang dimana jika wajahnya miring (*roll*) akan diluruskan terlebih dahulu. Selanjutnya wajah yang sudah diluruskan akan dideteksi objek tangannya, jika ada tangan terdeteksi maka tangan tersebut akan dibuat menjadi *blur*. Wajah dan tangan tersebut dilakukan masking menjadi objek berbentuk objek putih untuk bagian wajah, dan objek merah untuk bagian tangan. Objek hasil *masking* merah dan putih tersebut akan dibagi dua sesuai dengan titik tengah wajah. Hasil baginya akan dibandingkan dengan menghitung masing-masing luas *pixel* putihnya. Bagian yang diambil adalah bagian yang memiliki pixel putih lebih banyak dari bagian lainnya yang dimana hal tersebut berarti tidak ada atau objek oklusinya lebih sedikit. Berdasarkan objek *masking* yang dipilih, kemudian wajah asli akan di-*stretching* ke bentuk *mask* putih yang telah diluruskan bagian tengahnya. Lalu bagian wajah asli yang telah di-*stretching* tersebut diduplikasi dan dikombinasikan menjadi wajah yang seolah menghadap ke depan tanpa adanya tangan yang menutupi. Hasil wajah tersebutlah yang akan dilakukan proses FER dengan model-model FER yang telah ada. Seluruh alur pemrograman pada pengembangan ini dapat dilihat pada algoritma fungsi utama metode usulan (Lampiran A).

BAB V Hasil dan Evaluasi

Bab ini membahas hasil dari penerapan solusi yang telah dirancang. Selain itu, pada bagian ini juga akan dijelaskan evaluasi sesuai dengan rancangan rencana evaluasi pada bab sebelumnya. Setiap tahapan pengembangan dijelaskan secara detail dalam subbab masing-masing.

V.1 Hasil Metode Usulan


Bagian ini menyajikan hasil penerapan metode usulan terhadap data uji yang berupa wajah dengan oklusi tangan dan wajah yang tidak menghadap ke depan. Gambar V.1 menunjukkan hasil dimana gambar *input* adalah data yang diujikan, dan gambar *output* adalah hasil dari penerapan metode usulan.



Gambar V.1 Hasil percobaan metode usulan, (a) data wajah dengan oklusi tangan, (b) wajah dalam keadaan non-frontal

Gambar V.1 berisi dua subbagian (a) dan (b) yang masing-masing memperlihatkan contoh data wajah dari tujuh kategori emosi: *angry*, *disgust*, *fear*, *happy*, *neutral*, *sad*, dan *surprise*. Hasilnya menunjukkan keberhasilan metode usulan melakukan *frontalization* atau transformasi terhadap wajah sehingga orientasi dan struktur wajah menjadi lebih seragam dan frontal tanpa menghilangkan fitur yang penting untuk FER pada citra asli.

Penilaian keberhasilan metode usulan adalah dengan membandingkan emosi pada gambar sebelum diterapkan metode usulan dan gambar setelah diterapkan metode usulan.



Gambar V.2 Perbandingan probabilitas emosi pada gambar sebelum dan sesudah diterapkan metode usulan

Gambar V.2 menunjukkan pada gambar sebelum diterapkan metode usulan, hasil komposisi probabilitas emosinya menjadi ambigu sehingga hasil emosinya menjadi salah atau berbeda dengan emosi yang seharusnya. Namun, setelah gambar diterapkan metode usulan, maka emosinya menjadi benar atau sesuai dengan label emosi yang seharusnya disebabkan oleh probabilitas yang awalnya ambigu menjadi *confidence* terhadap label emosi yang seharusnya.

V.1.1 Hasil pada Wajah yang Tertutup Oklusi Tangan (Vertikal)

Pada bagian ini akan disajikan hasil pengukuran akurasi *before* dan *after* wajah dengan oklusi tangan sebagian menggunakan 4 model yaitu CNN, DeepFace, FaceLib, dan SVM sebagai validasi.

1. Hasil Evaluasi pada Model CNN

Hasil pengujian dengan model CNN pada Tabel V.1 menunjukkan bahwa metode usulan berhasil menaikkan akurasi seluruh label emosi pada wajah yang teroklusi tangan sebagian (vertikal) dengan rata-rata kenaikan keseluruhan sebesar 33.79%.


Tabel V.1 Hasil akurasi data wajah dengan oklusi tangan dengan CNN

Emosi	Jumlah Wajah terdeteksi (%)	Sebelum ^a (%)	Setelah ^b (%)	Selisih (b - a)	Kesimpulan
Angry	100	34.00	74.00	40.00	Naik
Disgust	100	2.00	45.50	43.50	Naik
Fear	100	37.50	56.50	19.00	Naik
Happy	100	33.50	71.50	38.00	Naik
Neutral	100	2.00	61.50	59.50	Naik
Sad	100	31.00	51.50	20.50	Naik
Surprise	100	33.00	49.00	16.00	Naik
Rata-rata				33.79	Naik

a. Akurasi sebelum penerapan metode usulan

b. Akurasi setelah penerapan metode usulan

Adapun visualisasi hasil pengujian data sebelum dan sesudah penerapan metode usulan dengan model CNN dapat dilihat pada Gambar V.3.



Gambar V.3 Visualisasi perbandingan akurasi data sebelum dan sesudah penerapan metode usulan pada data wajah dengan oklusi tangan menggunakan model CNN

2. Hasil Akurasi pada Model DeepFace


Hasil pengujian dengan model DeepFace pada Tabel V.2 menunjukkan bahwa metode usulan berhasil menaikkan akurasi pada beberapa label emosi pada wajah yang teroklusi tangan sebagian (vertikal). Walaupun terdapat penurunan dan tetap pada emosi *surprise* dan *fear*, namun secara keseluruhan hasilnya mengalami kenaikan rata-rata sebesar 14.29%.

Tabel V.2 Hasil akurasi data wajah dengan oklusi tangan dengan DeepFace

Emosi	Jumlah Wajah terdeteksi (%)	Sebelum ^a (%)	Setelah ^b (%)	Selisih (b - a)	Kesimpulan
Angry	100	36.50	38.00	1.50	Naik
Disgust	100	2.00	9.00	7.00	Naik
Fear	100	26.50	26.50	0.00	Tetap
Happy	100	16.00	70.00	54.00	Naik
Neutral	100	19.00	64.00	45.00	Naik
Sad	100	29.50	35.50	6.00	Naik
Surprise	100	35.50	22.00	-13.50	Turun
Rata-rata				14.29	Naik

- a. Akurasi sebelum penerapan metode usulan
b. Akurasi setelah penerapan metode usulan

Adapun visualisasi hasil pengujian data sebelum dan sesudah penerapan metode usulan dengan model DeepFace dapat dilihat pada Gambar V.4.



Gambar V.4 Visualisasi perbandingan akurasi data sebelum dan sesudah penerapan metode usulan pada data wajah dengan oklusi tangan menggunakan model DeepFace

3. Hasil Akurasi pada Model FaceLib

Hasil tidak biasa ditunjukkan oleh FaceLib, dimana model ini tidak berhasil mendeteksi wajah pada kondisi tertutup tangan sebagian. Sehingga jumlah data yang diukur hanyalah sejumlah wajah yang terdeteksi oleh model FaceLib. Hasil pengujian dengan model FaceLib pada Tabel V.3


menunjukkan bahwa metode usulan berhasil menaikkan akurasi pada beberapa label emosi pada wajah yang teroklusi tangan sebagian (vertikal). Terdapat penurunan pada emosi *Surprise*, walaupun demikian, secara keseluruhan hasilnya mengalami kenaikan rata-rata sebesar 10.66%.

Tabel V.3 Hasil akurasi data wajah dengan oklusi tangan dengan FaceLib

Emosi	Jumlah Wajah terdeteksi (%)	Sebelum ^a (%)	Setelah ^b (%)	Selisih (b - a)	Kesimpulan
Angry	76.00	40.79	50.00	9.21	Naik
Disgust	88.00	3.41	3.98	0.57	Naik
Fear	99.50	48.24	65.83	17.59	Naik
Happy	99.50	45.23	77.39	32.16	Naik
Neutral	99.50	22.11	41.21	19.10	Naik
Sad	99.50	55.78	66.83	11.05	Naik
Surprise	99.50	51.26	36.18	-15.08	Turun
Rata-rata				10.66	Naik

- Akurasi sebelum penerapan metode usulan
- Akurasi setelah penerapan metode usulan

Adapun visualisasi hasil pengujian data sebelum dan sesudah penerapan metode usulan dengan model FaceLib dapat dilihat pada Gambar V.5.



Gambar V.5 Visualisasi perbandingan akurasi data sebelum dan sesudah penerapan metode usulan pada data wajah dengan oklusi tangan menggunakan model FaceLib

4. Hasil Akurasi pada Model SVM

Hasil pengujian dengan model SVM pada Tabel V.4 menunjukkan bahwa keberhasilan metode usulan hanya pada emosi angry, happy, neutral, dan sad. Terdapat penurunan pada emosi *surprise* dan *fear*, dan tidak ada perubahan terhadap emosi *disgust*. Walaupun demikian, secara keseluruhan hasilnya mengalami kenaikan rata-rata sebesar 6.49%.


Tabel V.4 Hasil akurasi data wajah dengan oklusi tangan dengan SVM

Emosi	Jumlah Wajah terdeteksi (%)	Sebelum ^a (%)	Setelah ^b (%)	Selisih (b - a)	Kesimpulan
Angry	100	80.50	66.00	14.50	Naik
Disgust	100	0.50	0.50	0.00	Tetap
Fear	100	70.00	54.00	-16.54	Turun
Happy	100	36.00	81.50	45.50	Naik
Neutral	100	8.00	8.50	0.50	Naik
Sad	100	12.00	45.00	33.00	Naik
Surprise	100	3.00	0.50	-2.50	Turun
Rata-rata				6.49	Naik

a. Akurasi sebelum penerapan metode usulan

b. Akurasi setelah penerapan metode usulan

Adapun visualisasi hasil pengujian data sebelum dan sesudah penerapan metode usulan dengan model SVM dapat dilihat pada Gambar V.6.



Gambar V.6 Visualisasi perbandingan akurasi data sebelum dan sesudah penerapan metode usulan pada data wajah dengan oklusi tangan menggunakan model SVM

Hasil eksperimen pada wajah yang teroklusi oleh tangan sebagian menunjukkan bahwa metode usulan terbukti mampu mengembalikan fitur-fitur lokal wajah seperti mata, mulut, dan alis yang sebelumnya hilang akibat penutupan sebagian oleh tangan, sehingga meningkatkan kelengkapan informasi visual yang penting dalam proses ekstraksi representasi fitur. Kelengkapan fitur wajah menjadi faktor utama yang menentukan keberhasilan model dalam melakukan klasifikasi emosi secara akurat, karena kehilangan fitur dapat mengurangi konteks spasial yang dibutuhkan dalam pengenalan emosi (Ruan dkk. 2022; Chen dkk. 2023). Hasil evaluasi menunjukkan bahwa emosi “happy” merupakan label yang paling terpengaruh positif oleh penerapan metode usulan, dengan peningkatan akurasi dari kisaran 16–45% menjadi 70–80% pada keempat skema evaluasi. Peningkatan ini sejalan dengan temuan Eisenbarth dan Alpers (2011) yang menegaskan bahwa bagian mulut merupakan fitur dominan untuk mendeteksi emosi “happy”, di mana karakteristik sudut bibir yang terangkat menjadi penanda utama emosi tersebut. Namun, metode usulan juga menyebabkan sedikit penurunan akurasi pada emosi “surprise”, karena beberapa wajah dengan ground truth “surprise” cenderung terklasifikasi sebagai “fear”. Kondisi ini dapat dijelaskan oleh kemiripan ciri visual di antara keduanya—yakni mata dan mulut yang terbuka lebar—yang membuat model sulit membedakannya secara konsisten (Roy-Charland dkk., 2014). Secara keseluruhan, hasil ini menunjukkan bahwa metode pemulihan fitur lokal efektif meningkatkan performa model pada emosi dengan karakteristik emosi terbuka, meskipun masih memerlukan penyempurnaan untuk menangani emosi dengan pola visual yang beririsan.

V.1.2 Hasil pada Wajah dengan Kondisi Miring (*Non-Frontal*)

Pada bagian ini akan disajikan hasil pengukuran akurasi *before* dan *after* wajah dalam kondisi *non-frontal* menggunakan 4 model yaitu CNN, DeepFace, FaceLib, dan SVM sebagai validasi.

1. Hasil Akurasi pada Model CNN

Hasil pengujian pada wajah miring dengan model CNN pada Tabel V.5 menunjukkan bahwa metode usulan berhasil menaikkan akurasi emosi pada wajah dalam kondisi *non-frontal* dengan rata-rata kenaikan keseluruhan

sebesar 16.53%. Walaupun demikian, terdapat akurasi yang turun pada label emosi *angry* sebesar -26.39%.


Tabel V.5 Hasil akurasi data wajah miring (*non-frontal*) dengan CNN

Emosi	Jumlah Wajah terdeteksi (%)	Sebelum ^a (%)	Setelah ^b (%)	Selisih (b - a)	Kesimpulan
Angry	100	76.39	50.00	-26.39	Turun
Disgust	100	2.90	14.49	11.59	Naik
Fear	100	17.35	45.92	28.57	Naik
Happy	100	18.00	32.50	14.50	Naik
Neutral	100	4.50	33.00	28.50	Naik
Sad	100	21.66	73.89	52.23	Naik
Surprise	100	27.53	34.27	6.74	Naik
Rata-rata				16.53	Naik

a. Akurasi sebelum penerapan metode usulan

b. Akurasi setelah penerapan metode usulan

Adapun visualisasi hasil pengujian data sebelum dan sesudah penerapan metode usulan dengan model CNN dapat dilihat pada Gambar V.7.



Gambar V.7 Hasil akurasi data wajah *non-frontal* dengan CNN

2. Hasil Akurasi pada Model DeepFace

Hasil pengujian pada wajah miring dengan model DeepFace pada Tabel V.6 menunjukkan bahwa metode usulan hanya berhasil menaikkan akurasi emosi wajah dalam kondisi *non-frontal* pada emosi *angry* dan *neutral* saja


masing-masing sebesar 1.39% dan 14.00%, dengan sisanya mengalami penurunan. Walaupun demikian, jumlah penurunan rata-rata hanya sebesar -1.03%.

Tabel V.6 Hasil akurasi data wajah miring (*non-frontal*) dengan DeepFace

Emosi	Jumlah Wajah terdeteksi (%)	Sebelum ^a (%)	Setelah ^b (%)	Selisih (b - a)	Kesimpulan
Angry	100	34.72	36.11	1.39	Naik
Disgust	100	2.90	0.72	-2.18	Turun
Fear	100	27.55	19.39	-8.16	Turun
Happy	100	70.00	61.5	-8.50	Turun
Neutral	100	42.50	56.50	14.00	Naik
Sad	100	29.50	45.22	-3.19	Turun
Surprise	100	23.03	22.47	-0.56	Turun
Rata-rata				-1.03	Turun

- Akurasi sebelum penerapan metode usulan
- Akurasi setelah penerapan metode usulan

Adapun visualisasi hasil pengujian data sebelum dan sesudah penerapan metode usulan dengan model DeepFace dapat dilihat pada Gambar V.8.



Gambar V.8 Hasil akurasi data wajah *non-frontal* dengan DeepFace

3. Hasil Akurasi pada Model FaceLib

Hasil pengujian pada wajah miring dengan model FaceLib pada Tabel V.7 menunjukkan bahwa metode usulan hanya berhasil menaikkan akurasi pada emosi *disgust* dan *sad* saja masing-masing sebesar 26.53% dan 12.44%,

dengan sisanya mengalami penurunan. Jumlah rata-rata penurunan setelah penerapan metode usulan menggunakan FaceLib sebesar -5.12%.


Tabel V.7 Hasil akurasi data wajah miring (*non-frontal*) dengan FaceLib

Emosi	Jumlah Wajah terdeteksi (%)	Sebelum ^a (%)	Setelah ^b (%)	Selisih (b - a)	Kesimpulan
Angry	100	70.83	51.11	-9.72	Turun
Disgust	99.27	1.46	0.73	-0.73	Turun
Fear	100	22.45	48.98	26.53	Naik
Happy	99.50	74.87	53.77	-21.10	Turun
Neutral	99.50	46.73	31.66	-15.10	Turun
Sad	98.08	55.19	67.63	12.44	Naik
Surprise	97.75	54.02	25.86	-28.20	Turun
Rata-rata				-5.12	Turun

a. Akurasi sebelum penerapan metode usulan

b. Akurasi setelah penerapan metode usulan

Adapun visualisasi hasil pengujian data sebelum dan sesudah penerapan metode usulan dengan model FaceLib dapat dilihat pada Gambar V.9.



Gambar V.9 Hasil akurasi data wajah *non-frontal* dengan FaceLib

4. Hasil Akurasi pada Model SVM

Hasil pengujian pada wajah miring dengan model SVM pada Tabel V.8 menunjukkan bahwa metode usulan berhasil menaikkan akurasi emosi pada emosi *happy* dan *sad* saja masing-masing sebesar 11.50% dan 23.57%,

dengan sisanya mengalami penurunan. Walaupun demikian, secara keseluruhan hasilnya mengalami kenaikan rata-rata sebesar 2.21%.


Tabel V.8 Hasil akurasi data wajah miring (*non-frontal*) dengan SVM

Emosi	Jumlah Wajah terdeteksi (%)	Sebelum ^a (%)	Setelah ^b (%)	Selisih (b - a)	Kesimpulan
Angry	100	72.22	69.44	-2.78	Turun
Disgust	100	0.00	0.00	0.00	Tetap
Fear	100	68.37	63.27	-5.10	Turun
Happy	100	56.50	68.00	11.50	Naik
Neutral	100	14.50	5.00	-9.50	Turun
Sad	100	14.65	38.22	23.57	Naik
Surprise	100	3.93	1.69	-2.24	Turun
Rata-rata				2.21	Naik

a. Akurasi sebelum penerapan metode usulan

b. Akurasi setelah penerapan metode usulan

Adapun visualisasi hasil pengujian data sebelum dan sesudah penerapan metode usulan dengan model SVM dapat dilihat pada Gambar V.10.



Gambar V.10 Hasil akurasi data wajah *non-frontal* dengan SVM

Hasil eksperimen terhadap wajah non-frontal menunjukkan bahwa kenaikan akurasi secara signifikan hanya terjadi pada metode CNN yang dilatih hanya dengan menggunakan wajah *frontal*. Hal ini disebabkan oleh keluaran dari metode usulan yang berupa citra wajah *terfrontalization* dengan latar belakang hitam, sehingga menghasilkan tampilan yang serupa dengan data latih dan memudahkan

model mengenali emosi secara lebih akurat. Sebaliknya, penurunan akurasi terjadi pada metode DeepFace dan FaceLib, masing-masing sebesar -1.03% dan -5.12%. Pada *pipeline* DeepFace, sudah terdapat proses *frontalization* internal sehingga penerapan metode usulan menyebabkan terjadinya dua kali tahap *frontalization* yang berpotensi mengaburkan fitur penting wajah dan memperburuk representasi fitur oleh model (Engin dkk., 2018). Sejalan dengan temuan tersebut, Engin dkk. (2018) juga menyatakan bahwa metode simetris dengan pengambilan sebagian wajah atau *hard symmetry* dapat merusak fitur-fitur penting untuk representasi wajah, terutama pada model deep learning modern yang sangat bergantung pada keutuhan distribusi fitur lokal.

V.1.3 Hasil pada Wajah yang Tertutup Oklusi Tangan (Horizontal)

Walaupun metode usulan tidak dirancang untuk kasus seperti pada gambar V.11, namun metode usulan ini juga tetap diujikan terhadap data wajah dengan oklusi tangan horizontal, karena kondisi tersebut juga kerap terjadi terutama dalam dunia pembelajaran daring.



Gambar V.11 Kondisi wajah tertutup tangan pada bagian bawah (mulut)

Pengujian dilakukan hanya dengan *dataset* RafDB yang telah diseleksi dengan jumlah sesuai pada Tabel V.9, dimana *dataset* tersebut tidak ikut dilatihkan pada *training* model CNN yang hanya menggunakan data *frontal face* saja.

Tabel V.9 Jumlah data uji wajah dengan oklusi tangan (horizontal)

Angry	Disgust	Fear	Happy	Neutral	Sad	Surprise
106	62	73	200	200	200	200

Hasil penerapan metode usulan terhadap wajah dengan oklusi tangan di bagian mulut (Gambar V.11) tervisualisasi pada Gambar V.12, dimana hasil tangan yang menutupi bagian mulut dirubah menjadi sedikit *blur* dan seakan warnanya menyatu dengan *pixel* disekitarnya.



Gambar V.12 Hasil penerapan metode usulan terhadap wajah dengan oklusi tangan pada bagian bawah wajah

Hasil pada Tabel V.10 menunjukkan performa keberhasilan model untuk mendeteksi objek wajah. Terlihat dari 4 model yang diujikan, hanya FaceLib yang tidak berhasil secara 100% untuk mendeteksi wajah dengan oklusi tangan pada bagian mulut.

Tabel V.10 Performa model dalam mendeteksi wajah pada wajah yang teroklusi tangan pada bagian mulut

Emosi	CNN (%)	DeepFace (%)	FaceLib (%)	SVM (%)
Angry	100	100	96.22	100
Disgust	100	100	100	100
Fear	100	100	93.15	100
Happy	100	100	99.50	100
Neutral	100	100	99.50	100
Sad	100	100	99.50	100
Surprise	100	100	99.50	100

Pengujian dilakukan dengan menghitung selisih antara akurasi sebelum dan sesudah penerapan metode usulan. Hasilnya dapat dilihat pada Tabel V.11, angka positif menunjukkan bahwa metode usulan berhasil menaikkan akurasi, sedangkan angka negatif berarti metode usulan membuat akurasinya menjadi memburuk.

Tabel V.11 Hasil pengujian metode usulan pada wajah yang teroklusi tangan pada bagian mulut

Emosi	CNN (%)	DeepFace (%)	FaceLib (%)	SVM (%)
Angry	-2.83	4.72	-0.98	-9.44
Disgust	-1.61	-3.23	0.00	0.00
Fear	-12.33	-5.48	14.71	0.00
Happy	-4.00	-6.50	4.02	-2.00
Neutral	32.00	-9.50	-41.70	-10.5
Sad	-21.5	-11.00	12.57	16.5
Surprise	12.00	10.5	-9.04	-0.5
Rata-rata	0.25	- 2.93	- 2.92	- 0.85

V.1.4 Hasil Komparasi terhadap Metode *Frontalization* Lain

Dalam rangka memperkuat validasi metode usulan, eksperimen juga dilakukan dengan dengan membandingkan metode usulan dengan metode *frontalization* yang dilakukan oleh Tsai dkk., (2021), dimana proses *frontalization* juga dilakukan dengan hanya menggunakan pemrosesan gambar 2D (Gambar V.13).



Gambar V.13 Metode *frontalization* wajah 2D oleh Tsai dkk., (2021)



Gambar V.14 Hasil komparasi, (A) gambar *input*, (B) metode usulan, (C) metode lain (Tsai dkk., 2021)

Tabel V.12 Hasil komparasi metode *frontalization*

Emosi	CNN (%)		DeepFace (%)		FaceLib (%)		SVM (%)	
	a	b	a	b	a	b	a	b
Angry	-34.62	-26.39	-7.70	1.39	-14.29	-9.72	3.85	-2.78
Disgust	12.93	11.59	-3.40	-2.18	-2.04	-0.73	-0.68	0.00
Fear	17.82	28.57	-10.89	-8.16	16.83	26.53	-30.7	-5.10
Happy	29.00	14.50	-6.00	-8.50	4.53	-21.10	22.00	11.5
Neutral	28.00	28.50	17.50	14.00	-5.02	-15.07	1.00	-9.50
Sad	27.10	52.23	-15.49	-3.19	6.50	12.44	20.64	23.57
Surprise	25.34	6.74	-6.00	-0.56	-20.41	-28.16	-2.00	-2.24
Rata-rata	15.08	16.53	-4.57	-1.03	-1.99	-5.12	2.02	2.21

a. Metode *frontalization* oleh Tsai dkk., (2021)

b. Metode usulan pada penelitian ini

Hasil pada Tabel V.12 menunjukkan bahwa rata-rata dari perbandingan kedua metode tersebut tidak memiliki perbedaan yang terlalu jauh. Hasil komparasi ini terbatas hanya pada gambar wajah *non-frontal*, karena metode *frontalization* yang dilakukan oleh Tsai dkk., (2021) tidak memiliki fitur untuk menghapus objek oklusi tangan.

V.2 Pembahasan

Bagian ini akan menjelaskan analisis mendalam serta beberapa temuan yang terjadi berdasarkan hasil eksperimen yang telah dijelaskan pada sub bab V.1.

V.2.1 Performa *Face Detector* pada Model

Tahap pertama dalam suatu sistem *Facial Expression Recognition* (FER) adalah proses deteksi wajah. Jika tahap ini gagal, seluruh *pipeline* selanjutnya akan berhenti karena sistem tidak dapat mengekstraksi fitur emosi dari citra yang tidak teridentifikasi sebagai wajah. Berdasarkan hasil penelitian yang dilakukan menggunakan empat metode *state-of-the-art* yaitu CNN, DeepFace, Facelib, dan SVM, hanya metode Facelib yang mengalami kegagalan dalam deteksi wajah, sementara tiga metode lainnya berhasil 100% mengenali wajah. Facelib menggunakan algoritma *Single Shot Multibox Detector* (SSD) pada tahap deteksi wajah.

SSD merupakan arsitektur *one-stage detector* yang mengombinasikan ekstraksi fitur berbasis CNN dengan mekanisme *multi-scale feature map* untuk mendeteksi objek dalam berbagai ukuran secara simultan. Keunggulan utamanya terletak pada kecepatan inferensi yang tinggi karena proses klasifikasi dan *regresi bounding box* dilakukan dalam satu langkah. Namun, sejumlah penelitian menunjukkan bahwa efisiensi ini didapat dengan mengorbankan nilai kepresisian, khususnya dalam kondisi *occlusion* atau *pose variation*.

SSD bekerja optimal pada citra wajah *frontal* dan tanpa gangguan latar, tetapi performanya menurun drastis ketika sebagian wajah tertutup (misalnya oleh tangan atau masker) atau ketika wajah berada dalam posisi *non-frontal* (Qu dkk., 2022). Hasil pada tabel V.3, dan tabel V.7 membuktikan teori tersebut, dimana performa Facelib dengan detektor SSD pada wajah yang mengalami oklusi oleh tangan hanya

mencapai 76% dan 88% pada kelas emosi *angry* dan *disgust*, sementara kelas lainnya (*fear*, *happy*, *neutral*, *sad*, dan *surprise*) menunjukkan hasil lebih tinggi, yaitu sekitar 99.5%. Untuk citra wajah non-frontal, performa deteksi masing-masing kelas adalah 100%, 99.27%, 100%, 99.50%, 99.50%, 98.08%, dan 97.75%. Penurunan performa deteksi pada wajah teroklusi cukup selaras dengan penelitian Jang dkk. (2019), yang menunjukkan bahwa varian algoritma Face-SSD hanya mampu mempertahankan akurasi di kisaran 80 - 95% tergantung derajat oklusi (Jang dkk., 2019).

Dengan demikian, meskipun pada penelitian lain disebutkan bahwa SSD menawarkan performa waktu nyata (*real-time performance*) yang unggul (Tariyal dkk., 2024), hasil pada penelitian ini menunjukkan bahwa tanpa peningkatan arsitektur dan tahap *pre-alignment*, performa SSD masih kurang memadai untuk aplikasi FER di lingkungan dunia nyata yang sarat dengan oklusi dan variasi pose.

V.2.2 Wajah yang Teroklusi oleh Tangan Sebagian

Adanya tangan yang menutupi sebagian wajah merupakan salah satu bentuk oklusi parsial yang paling umum terjadi dalam kondisi nyata, seperti ketika seseorang bereaksi secara spontan dalam emosi tertentu ataupun dalam keadaan bosan ketika mengikuti pembelajaran daring, dimana tangan biasanya digunakan untuk menopang kepala atau wajah. Oklusi jenis ini secara signifikan menurunkan performa sistem FER karena menghalangi area wajah yang berperan penting dalam penentuan emosi, seperti mata, hidung, dan terutama mulut. Ketika area tersebut hilang dari citra gambar wajah yang diujikan, representasi fitur yang dihasilkan dari proses ekstraksi menjadi tidak utuh, sehingga model kesulitan memetakan pola ke emosi yang benar.

Hasil eksperimental memperlihatkan efek tersebut dengan jelas. Pada data uji sebelum dilakukan *pre-processing* dengan metode usulan (data “*before*”), rata-rata akurasi FER hanya sebesar 24.71%, 23.57%, 38.12%, dan 30.08% masing-masing untuk model CNN, DeepFace, Facelib, dan SVM. Angka tersebut menunjukkan bahwa hampir dua pertiga klasifikasi gagal mengenali emosi dengan benar ketika wajah tertutup tangan. Terutama pada model berbasis deep learning seperti CNN dan DeepFace, performa yang rendah ini menunjukkan bahwa meskipun model

mampu belajar fitur kompleks, model tersebut tetap sangat bergantung pada keutuhan informasi spasial wajah.


Setelah dilakukan *pre-processing* menggunakan metode usulan yang berfungsi untuk menghilangkan objek tangan pada gambar wajah, terjadi peningkatan akurasi yang signifikan. Nilai akurasi naik menjadi 58.5%, 37.9%, 48.8%, dan 36.6% untuk keempat model yang sama. Kenaikan rata-rata di atas 20% ini memperlihatkan efektivitas tahapan *pre-processing* dalam memulihkan informasi penting yang sebelumnya hilang. Proses ini membantu model menghasilkan representasi fitur yang lebih stabil sekalipun sebagian wajah tetap tidak terlihat karena tertutup oleh tangan. Emosi *neutral* dan *happy* adalah yang paling terdampak secara positif oleh metode yang diusulkan dalam kondisi wajah sebagian tertutup tangan secara vertikal. Kenaikan akurasi drastis pada emosi *neutral* (hingga +59.5% dengan CNN dan +45% dengan DeepFace) mengindikasikan bahwa representasi emosi *neutral* sangat terbantu dengan proses *pre-processing* menggunakan metode usulan pada area yang terhalang tangan, kemungkinan karena karakteristik emosi *neutral* yang kurang menonjol pada fitur-fitur dinamis seperti mulut, sehingga model lebih mudah mengenali struktur utama wajah meski sebagian tertutup.

Peningkatan tajam juga terjadi pada emosi *happy*, terlihat pada DeepFace (+54%), FaceLib (+32.16%), dan SVM (+45.5%). Hal ini mengindikasikan bahwa indikator visual *happy*, seperti pergerakan pipi dan kontraksi otot *orbicularis oculi* di sekitar mata, tetap dapat ditangkap model walaupun beberapa area wajah tertutup tangan.

Sebaliknya, emosi *surprise* dan *fear* merupakan yang paling terdampak secara negatif dengan penurunan akurasi cukup tajam, terutama pada model DeepFace dan FaceLib. Penurunan ini menandakan bahwa fitur emosi pada kedua emosi tersebut, seperti pelebaran mata atau perubahan tiba-tiba di area atas wajah, sangat rentan terhadap gangguan akibat oklusi tangan pada setengah bagian wajah. Dengan adanya tangan yang menutupi sebagian area mata atau dahi, pola ciri khas dari emosi *surprise* dan *fear* menjadi sulit dikenali oleh model. Temuan ini menunjukkan bahwa pentingnya area atas wajah dalam mendeteksi emosi yang sangat dinamis dan menekankan perlunya pengembangan algoritma yang lebih sensitif terhadap keberadaan oklusi di area penting emosi, seperti mata dan alis.

Dari sisi interpretasi sistem, peningkatan ini juga mengindikasikan bahwa pendekatan FER yang tangguh terhadap oklusi memerlukan penanganan secara keseluruhan pada setiap tahap deteksi atau normalisasi wajah. Dengan kata lain, bukan hanya arsitektur model yang menentukan performa akhir, tetapi juga kualitas dan keutuhan *input* yang diterima. Dalam konteks aplikasi dunia nyata penertapan FER pada *smart education* atau *smart campuss* ini, masalah tangan yang menutupi wajah harus dipertimbangkan sejak tahap desain *pipeline* agar sistem dapat tetap handal meskipun menghadapi objek wajah yang tidak sepenuhnya terbuka.

Ada kelemahan dalam metode yang diusulkan ini, dimana terdapat kondisi model *hand-detector* dari pustaka *MediaPipe* gagal dalam mendeteksi keberadaan tangan pada wajah sehingga mengagalkan proses setelahnya yang menjadikan *output* otomatis menjadi tidak seperti yang diharapkan (Gambar V.15 (B)). Adapun jumlah kegagalan deteksi tangan adalah masing-masing sebanyak : *angry* 9, *disgust* 6, *fear* 13, *happy* 17, *neutral* 11, dan *surprise* 17 dari total 200 gambar per kelas emosi, jadi bisa disimpulkan tingkat kegagalan *hand-detection* di bawah 0.1%.




Gambar V.15 Hasil metode usulan, (A) kondisi berhasil, (B) kondisi gagal

Kegagalan model *hand-detector* dari *MediaPipe* dalam mendeteksi keberadaan tangan pada wajah umumnya disebabkan oleh kombinasi faktor teknis dan kondisi visual yang kompleks. Salah satu penyebab utama adalah *overlap* antara tangan dan wajah, dimana warna kulit yang serupa serta jarak tangan yang terlalu dekat membuat sistem kesulitan membedakan area tangan dari kontur wajah (Pu dkk., 2023). Kualitas citra dan pencahayaan juga berperan penting seperti pada kasus pencahayaan yang tidak merata, bayangan di area wajah, atau tingkat refleksi cahaya yang tinggi dapat menurunkan nilai *confidence score* di bawah ambang

batas 0.7 yang telah ditetapkan oleh model *MediaPipe*. Kegagalan juga kerap terjadi ketika ukuran tangan dalam citra terlalu besar atau terlalu kecil akibat jarak kamera yang tidak sesuai dengan rasio deteksi ideal.

V.2.3 Wajah dengan Kondisi Miring (*Non-Frontal*)

Bentuk oklusi lainnya yang diuji pada penelitian ini adalah keadaan wajah *non-frontal* ataupun *pose-invariant*. Walaupun hasil *pre-processing* dengan metode usulan ini mampu menaikkan akurasi dari model FER pada data wajah yang tertutup tangan sebagian (vertikal) oleh tangan, namun metode usulan ini juga ternyata dapat menurunkan akurasi dari sebuah model FER pada kondisi wajah *non-frontal*. Hasil experimental (sub bab V.1.2) menunjukkan keadaan data “before” akurasi dari model CNN, DeepFace, FaceLib, dan SVM adalah masing-masing sebesar 24.05%, 35.59%, 46.51%, dan 32.88%. Setelah diterapkan *pre-processing* dengan metode usulan akurasinya menjadi 40.6%, 34.6%, 41.4%, dan 35.1%. Pengaruh positif hanya terjadi pada model CNN dan SVM, sedangkan pada model DeepFace dan FaceLib terjadi penurunan akurasi rata-rata. Kenaikan di atas 15% terjadi pada model CNN terjadi karena model dilatih dengan hanya data wajah *frontal* saja, sehingga data uji hasil *pre-processing* yang berupa wajah *frontal* dengan mudah dikenali oleh model.



Gambar V.16 Arsitektur DeepFace (Taigman dkk., 2014)

Adapun untuk DeepFace, terjadi penurunan akurasi sebesar -1.03%, karena pada DeepFace (Gambar V.16) sudah menerapkan *pre-processing* berupa proses *frontalization* pada arsitekturnya. Sehingga ketika diujikan dengan metode usulan terjadi dua kali *frontalization* yaitu pertama dengan metode usulan, lalu dilakukan *frontalization* kembali oleh Deepface. Proses ganda ini menyebabkan redundansi transformasi spasial, dimana wajah yang sebelumnya telah *frontalization* kembali diproses pada tahap internal DeepFace, mengakibatkan perubahan kecil pada

struktur wajah yang justru menurunkan ketepatan klasifikasi. Namun demikian, penurunan akurasi ini masih tergolong kecil dan tidak berdampak signifikan terhadap performa keseluruhan model. Hal yang sama terjadi pada FaceLib, dimana FaceLib sudah mempunyai *face align* pada arsitekturnya, hal tersebut tampak pada dokumentasi penggunaan kode FaceLib pada *source* resminya (Ayoubi, 2020).

Proses *frontalization* yang diterapkan dalam penelitian ini bertujuan untuk menormalkan orientasi wajah agar sejajar terhadap bidang pandang kamera. Namun demikian, proses tersebut berpotensi menimbulkan efek samping berupa penyamarataan tekstur pada area wajah tertentu (Hassner dkk., 2015). Dalam kondisi dimana salah satu sisi wajah tertutup tangan atau mengalami perbedaan distribusi pencahayaan, maka proses replikasi ini dapat menghasilkan tekstur buatan (*artificial texture*) pada area tersebut, dimana tekstur buatan ini dapat mengubah keaslian pola fitur lokal di sekitar area yang direkonstruksi, sehingga memengaruhi representasi citra yang digunakan oleh sistem pengenalan emosi. Dalam konteks ini, model FaceLib yang bergantung pada informasi spasial dan berdasarkan tekstur untuk mengekstraksi fitur emosi dapat terjadi salah penafsiran pola hasil replikasi tersebut sebagai karakteristik emosi yang berbeda dari kondisi sebenarnya. Akibatnya, proses klasifikasi emosi berpotensi mengalami penurunan akurasi akibat ketidaksesuaian struktur tekstur hasil *frontalization*.

Sejalan dengan hasil perbandingan metode usulan dengan metode *frontalization* lain yang dilakukan oleh K.Y. Tsai, et. al., (2021) (Tsai dkk., 2021) pada tabel V.12. Hasilnya menunjukkan bahwa baik metode usulan pada penelitian ini maupun metode pembanding tersebut memiliki kesimpulan yang sama yaitu adanya kenaikan akurasi pada CNN dan SVM, lalu terdapat penurunan akurasi pada DeepFace dan FaceLib, dimana seperti yang sudah dijelaskan bahwa DeepFace dan FaceLib memiliki paket *pipeline* yang sudah memiliki proses penyesuaian (*align*) wajah di dalamnya, sehingga melakukan *pre-processing* sebelum menggunakan DeepFace dan FaceLib berpotensi untuk menurunkan akurasinya.

Secara umum, hasil ini memperlihatkan bahwa efek *pre-processing* terhadap kinerja model sangat bergantung pada desain dan karakteristik arsitektur yang digunakan. Jika tahap koreksi citra selaras dengan strategi ekstraksi fitur di dalam

model, maka peningkatan akurasi dapat dicapai secara konsisten. Namun, jika transformasi awal justru berpotensi menggandakan fungsi yang telah ada pada *pipeline*, maka dampaknya bisa sebaliknya. Temuan ini menegaskan pentingnya keselarasan antara strategi *pre-processing* dan rancangan internal model agar hasil pengenalan emosi tetap optimal dalam berbagai kondisi wajah terutama pada wajah *non-frontal*.

V.2.4 Oklusi Parsial pada Area Mulut

Berdasarkan hasil perubahan rata-rata akurasi sebelum dan sesudah penerapan metode pada wajah dengan oklusi tangan di area mulut, terlihat bahwa penurunan yang terjadi relatif tidak signifikan pada sebagian besar model. Misalnya, CNN hanya mengalami peningkatan sangat kecil yaitu +0.25%, sementara DeepFace dan FaceLib justru menunjukkan penurunan rata-rata -2.93% dan -2.92%. SVM juga hanya turun sedikit sebesar -0.85%. Dapat disimpulkan bahwa metode yang diusulkan tidak memberikan dampak berarti dalam meningkatkan performa pengenalan emosi pada kasus oklusi tangan di area mulut, serta tidak memunculkan perbedaan besar dibandingkan kondisi awal. Hal ini menandakan bahwa karakteristik fitur emosi di area mulut yang tertutup tangan sulit dinormalkan melalui pendekatan yang digunakan, sehingga model tidak memperoleh informasi baru yang substansial untuk proses klasifikasi.


Hasil ini sejalan dengan fenomena yang telah ditemui pada penelitian pengenalan emosi wajah ketika area mulut tertutup, seperti pada kasus penggunaan masker medis. Berbagai studi telah membuktikan bahwa emosi seperti bahagia, sedih, dan marah lebih sulit dikenali jika bagian mulut dan hidung tertutup masker (Grahlow dkk., 2022)(Ruan dkk., 2022b). Penurunan akurasi juga dapat disebabkan oleh hilangnya beberapa karakteristik emosi penting di area tersebut seperti senyuman, pergerakan bibir, atau kerutan hidung, yang memiliki kontribusi besar pada deteksi emosi tertentu. Pada kondisi ini, sistem cenderung lebih bergantung pada fitur bagian atas wajah seperti mata dan alis, yang sebenarnya kurang informatif untuk sejumlah emosi.

V.3 Aplikasi LMS

Pada bagian ini akan dijelaskan hasil dari rancangan halaman antarmuka aplikasi LMS yang digunakan sebagai media integrasi sistem FER untuk mendapatkan data emosi pemelajar dalam pembelajaran asinkron. Adapun bagian-bagian tampilan antarmukanya antara lain: halaman *login*, halaman *dashboard*, halaman akses materi pembelajaran asinkron, dan halaman *engagement* pemelajar.

1. Halaman Login


Halaman *login* pada Gambar V.17 merupakan tampilan pertama kali ketika pengguna membuka aplikasi dalam keadaan belum melakukan proses *login*. Adapun komponen yang terdapat pada halaman *login* antara lain, *form input username*, *password*, dan sebuah tombol *login*.



Gambar V.17 Halaman *login*

2. Halaman Dashboard


Halaman *dashboard* pada Gambar V.18 adalah halaman setelah pengguna melakukan login sesuai hak aksesnya masing-masing. Halaman ini berisi beberapa informasi seperti jumlah pengajar, jumlah mahapemelajar, jumlah kelas, dan jumlah matakuliah.



Gambar V.18 Halaman *dashboard*

3. Halaman Akses Materi Pembelajaran asinkron


Halaman akses materi pembelajaran asinkron pada Gambar V.19 berisi beberapa komponen seperti *frame* video materi, *frame* tangkapan *webcam*, tombol *media-player*, dan beberapa keterangan analisis wajah yang ditangkap oleh *webcam*.



Gambar V.19 Halaman akses materi pembelajaran asinkron

4. Halaman Ringkasan Engagement Siswa


Halaman hasil ringkasan *engagement* pemelajar akan berisi beberapa data statistik *engagement* dari pemelajar saat melakukan pembelajaran asinkron antara lain, data *engagement* per detik, persentase emosi, kesimpulan *engagement*, grafik perubahan emosi, dan interpretasi hasil menggunakan *Large Language Model* (LLM) Gemini yang berisi ringkasan *engagement* pemelajar dan rekomendasi evaluasi materi untuk pengajar.



Gambar V.20 Data *engagement* pemelajar

Data *engagement* pemelajar pada Gambar V.20 berisi status *engagement* per detik dari materi video yang diberikan, sehingga akan tampak perubahan status

engagement pemelajar pada bagian yang mana saja dan bisa menjadi bahan untuk evaluasi materi bagi pengajar.



Gambar V.21 Data persentase emosi dan kesimpulan *engagement* pemelajar

Persentase emosi pemelajar menunjukkan variasi emosi pemelajar selama mengikuti pelajaran. Pada Gambar V.21 juga ditampilkan kesimpulan status *engagement* dari pemelajar yang merupakan tingkat *engagement* dominan dari keseluruhan data status *engagement* dan persentase *engagement* untuk seluruh status, mulai dari *highly engaged* hingga *very not engaged*.



Gambar V.22 Grafik perubahan emosi pemelajar

Grafik perubahan emosi pemelajar pada Gambar V.22 dapat dijadikan bahan pengajar untuk mengevaluasi respon emosional pemelajar atas materi yang diberikan serta menentukan isi materi belajar yang lebih sesuai.


Ringkasan Engagement Siswa
Berikut adalah analisis dan rekomendasi berdasarkan data yang diberikan, dengan timestamp pertama diubah menjadi detik ke 00:00:01. Secara umum, siswa menunjukkan tingkat engagement yang tinggi terhadap materi "Konten 15 Detik". Mayoritas data mencatat engagement sebagai "Highly Engaged" dan "face_detected" true, dengan emosi yang dominan adalah "neutral". Terdapat beberapa momen di mana engagement menurun menjadi "Boredom" atau "Sleepy" yang disertai dengan emosi negatif seperti "sad" dan "angry", atau tetap "neutral". Emosi dominan secara keseluruhan adalah neutral.
Rekomendasi Perbaikan
Perlu dievaluasi kembali bagian materi yang bertepatan dengan timestamp 00:00:08, 00:00:15, 00:00:18, 00:00:20, 00:00:25, 00:00:26, dan 00:00:27 karena pada waktu-waktu tersebut, terdapat indikasi penurunan engagement siswa. Pengajar dapat mencoba variasi metode penyampaian, contohnya dengan memberikan selingan berupa pertanyaan interaktif, kuis singkat, atau studi kasus yang relevan untuk menjaga fokus siswa dan mencegah rasa bosan atau mengantuk.

Gambar V.23 Hasil intepretasi hasil menggunakan LLM

Gambar V.23 merupakan hasil interpretasi statistik yang berisi ringkasan *engagement* pemelajar serta rekomendasi perbaikan materi untuk pengajar.

V.4 Implementasi FER pada LMS

Tahapan pertama dari implementasi sistem FER pada LMS adalah menangkap wajah pemelajar dari sisi *front-end* yaitu menggunakan *javascript*. *Frame* wajah akan dikirimkan ke *back-end flask* untuk dilakukan *pre-processing* dengan metode usulan dan diklasifikasikan emosinya oleh model. DeepFace dipilih sebagai model deteksi emosi dalam aplikasi LMS. Beberapa pertimbangannya adalah kemampuan DeepFace yang bisa dijalankan hanya dengan menggunakan CPU (Taigman dkk., 2014) dan berbasis REST API, sehingga dapat digunakan pada perangkat yang tidak memiliki spesifikasi yang tinggi dan juga praktis dalam implementasinya. Hasil analisis wajah yang berupa data emosi, arah mata, dan kepala dikirimkan kembali oleh *back-end* ke *front-end* untuk ditampilkan dalam halaman antarmuka, dimana data tersebutlah yang akan disimpan dalam bentuk JSON dan akan menjadi bahan analisis oleh sistem dimana hasilnya akan diproses menggunakan model LLM Gemini untuk mendapat *insight* dari hasil pembelajaran pemelajar.



Gambar V.24 Keterangan hasil analisis wajah pemelajar per *frame*, (a) kondisi *highly engaged*, wajah lurus ke layar tanpa halangan, (b) kondisi *highly engaged*, wajah lurus ke layar dengan halangan tangan, (c) kondisi *boredom*, wajah tidak menghadap ke layar, (d) kondisi *sleepy*, mata tertutup, (e) kondisi *boredom* kepala ditopang tangan

Gambar V.24 menunjukkan contoh beberapa kondisi wajah pemelajar saat pembelajaran asinkron, yaitu kondisi ketika pemelajar menonton materi yang diberikan pengajar dalam bentuk video. Aplikasi hanya diberi fitur tombol *play*, *pause*, dan *replay* sehingga pemelajar tidak bisa mempercepat video pembelajaran. Tampak pada Gambar V.24 dimana ada beberapa skenario yang diujikan, mulai dengan *engagement highly engaged*, hingga pengujian dalam kondisi *boredom* atau bosan dan *sleepy*. Pengujian dilakukan dengan mengkondisikan beberapa gestur tangan sesuai dengan skenario yang dibuat.

Gambar V.24 (b) tampak sistem masih bisa melakukan klasifikasi emosi dengan tepat walaupun terdapat tangan yang menutupi sebagian wajah. Pada halaman antarmuka aplikasi juga tidak ditampilkan proses-proses *back-end*. Aplikasi hanya akan menampilkan kondisi wajah pemelajar saja dengan hasil yang sudah diklasifikasi oleh model FER. Hal tersebut atas pertimbangan bahwa ketika proses *back-end* ditampilkan, maka akan memperberat kinerja di bagian *front-end* sehingga bisa mengganggu kenyamanan pengguna.

Pengujian dilakukan dengan menerapkan beberapa skenario terhadap tiga pemelajar untuk mengevaluasi tingkat *engagement* mereka selama proses pembelajaran. Siswa 1 akan diskenariokan untuk dominan pada kondisi *boredom*, pemelajar 2 diskenariokan untuk dominan *confused*, dan pemelajar 3 akan diskenariokan untuk dominan *highly engaged*. Hasil pengujian yang dirangkum dalam Tabel V.13 menunjukkan variasi yang signifikan dalam pola *engagement* antar pemelajar. Lebih lengkap tentang proses, hasil, dan visualisasi dari pengujian evaluasi tingkat *engagement* pemelajar dapat dilihat pada lampiran B.

Tabel V.13 Hasil ringkasan beberapa skenario pengujian *engagement* pemelajar

Siswa	<i>Highly Engaged (%)</i>	<i>Confused (%)</i>	<i>Boredom (%)</i>	<i>Sleepy (%)</i>	<i>Very Not Engaged (%)</i>
Siswa 1	20.0	11.11	53.33	8.89	6.67
Siswa 2	13.33	51.11	22.22	11.11	2.22
Siswa 3	51.11	2.22	35.56	6.67	4.44

BAB VI Kesimpulan dan Saran

Bab ini memuat kesimpulan yang menjelaskan tingkat pencapaian tujuan penelitian tesis terhadap permasalahan yang telah dikaji. Selain itu, bab ini juga menyajikan beberapa saran yang dapat dijadikan acuan untuk pengembangan penelitian selanjutnya.

VI.1 Kesimpulan

Penelitian ini menghasilkan sebuah pendekatan *pre-processing* gambar 2D berbasis pemanfaatan setengah wajah untuk mengatasi permasalahan oklusi dan pose *non-frontal* dalam klasifikasi emosi wajah pemelajar pada pembelajaran daring. Pendekatan ini dirancang untuk meningkatkan akurasi sistem klasifikasi emosi, sekaligus mendukung optimasi performa sistem klasifikasi *engagement* berbasis *multi-modal*.

Berdasarkan analisis dan temuan yang diperoleh, kesimpulan yang dapat diambil adalah sebagai berikut:

1. Pengembangan teknik *pre-processing* gambar 2D berbasis setengah wajah terbukti mampu meningkatkan akurasi klasifikasi emosi pada kondisi wajah teroklusi maupun *non-frontal*. Hal ini menunjukkan bahwa strategi pemanfaatan setengah wajah dapat menjadi solusi efektif dalam mengurangi dampak kehilangan informasi visual akibat oklusi tangan atau variasi pose kepala.
2. Evaluasi efektivitas metode *pre-processing* memperlihatkan peningkatan performa yang signifikan pada kasus oklusi tangan vertikal (misalnya wajah tertutup tangan di area mata, pipi, alis, dan sebagian mulut), dengan rata-rata peningkatan akurasi mencapai 33.79% pada CNN dan 14.29% pada DeepFace. Pada wajah dengan kemiringan pose (*non-frontal*), metode ini juga memberikan kenaikan akurasi meskipun bersifat tidak signifikan, sehingga tetap menunjukkan potensi model untuk tetap optimal pada variasi orientasi wajah. Namun, pada oklusi di seluruh area mulut, metode ini tidak memberikan peningkatan berarti, bahkan menurunkan akurasi pada

beberapa model. Hal ini menegaskan bahwa informasi dari area mulut sangat krusial dalam klasifikasi emosi tertentu seperti *happy*, *sad*, dan *fear*.

3. Implementasi aplikasi prototipe yang dikembangkan mampu menampilkan hasil pengukuran tingkat *engagement* pemelajar secara interaktif. Hal ini membuktikan bahwa sistem dapat diintegrasikan dalam konteks pembelajaran daring, sehingga berpotensi mendukung pemantauan *engagement* pemelajar secara lebih objektif dan adaptif terhadap kondisi visual yang menantang.

Secara keseluruhan, penelitian ini menunjukkan bahwa pendekatan *pre-processing* berbasis setengah wajah memiliki potensi untuk meningkatkan *robustness* sistem pengenalan emosi terhadap oklusi parsial dan pose *non-frontal*, serta dapat diimplementasikan dalam aplikasi pemantauan *engagement* pemelajar daring.

VI.2 Saran

Berdasarkan hasil eksperimen, terdapat beberapa kondisi dimana sistem mengalami kegagalan dan hasilnya tidak sesuai dengan yang diharapkan. Hal tersebut dapat dijadikan bagian yang perlu dikembangkan lebih lanjut, sehingga saran untuk pengembangan selanjutnya antara lain:

1. Faktor seperti kegagalan deteksi tangan oleh *hand-detector MediaPipe* menjadi salah satu aspek yang memengaruhi kinerja keseluruhan sistem, khususnya pada kondisi pencahayaan rendah atau pose tangan ekstrem. Keterbatasan ini membuka ruang untuk membangun sebuah model deteksi tangan yang lebih robust terhadap beberapa kondisi tangan untuk diimplementasikan ke dalam sistem FER.
2. Hasil penelitian ini terbatas hanya pada *dataset* yang digunakan dalam eksperimen ini, yang memiliki karakteristik dan distribusi citra tertentu. Oleh karena itu, performa metode mungkin akan berbeda apabila diuji pada *dataset* dengan resolusi lebih beragam, tingkat oklusi lebih kompleks, atau latar visual yang berbeda. Penelitian selanjutnya bisa dengan menggunakan *dataset* skenario yang beragam, ataupun membuat *dataset* mandiri dengan memanfaatkan teknologi *generative AI*, dimana hanya dengan bermodalkan

satu wajah bisa menghasilkan banyak pose dan keadaan wajah, sehingga *dataset* menjadi lebih variatif.

3. Pemanfaatan pendekatan *multi-modality* melalui integrasi berbagai fitur, seperti penggunaan *landmark* tubuh secara menyeluruh dan kombinasi dengan fitur suara, dapat menjadi strategi yang efektif untuk meningkatkan akurasi penilaian *engagement* pemelajar. Dengan menggabungkan data dari emosi wajah, postur tubuh, serta karakteristik vokal, sistem penilaian dapat memperoleh informasi yang lebih kaya dan holistik mengenai tingkat *engagement* pemelajar dalam pembelajaran daring. Integrasi ini berpotensi memperkuat kemampuan sistem dalam mengenali dinamika emosi dan perilaku pemelajar, sehingga dapat menghasilkan analisis yang lebih komprehensif untuk mendukung pengembangan teknologi pendidikan di masa depan.
4. Kecepatan proses menyangkut efisiensi proses keseluruhan *pipeline* perlu untuk dipertimbangkan, semakin efisien sistem, semakin banyak *frame* yang bisa diproses, sehingga perubahan emosi secara tiba-tiba bisa ditangkap. Penelitian selanjutnya disarankan untuk melakukan optimasi program baik dari sisi *back-end* atau *front-end* sehingga LMS dengan fitur deteksi emosi bisa berjalan lancar di spesifikasi *resource* yang rendah.

DAFTAR PUSTAKA

- Afzal, S., Khan, H. A., Piran, M. J., & Lee, J. W. (2024). A Comprehensive Survey on Affective Computing: Challenges, Trends, Applications, and Future Directions. *IEEE Access*, 12, 96150–96168.
<https://doi.org/10.1109/ACCESS.2024.3422480>
- Aly, M., Ghallab, A., & Fathi, I. S. (2023). Enhancing Facial Expression Recognition System in Online Learning Context Using Efficient Deep Learning Model. *IEEE Access*, 11(November), 121419–121433.
<https://doi.org/10.1109/ACCESS.2023.3325407>
- Ayoubi, S. (2020). *FaceLib: Face Analysis*.
<https://github.com/sajjadayobi/FaceLib>
- Bao, J., Tao, X., & Zhou, Y. (2024). An Emotion Recognition Method Based on Eye Movement and Audiovisual Features in MOOC Learning Environment. *IEEE Transactions on Computational Social Systems*, 11(1), 171–183.
<https://doi.org/10.1109/TCSS.2022.3221128>
- Beekman, R., Tijssen, C. C., Visser, L. H., & Schellens, R. L. L. A. (2002). Dropped head as the presenting symptom of primary hyperparathyroidism [3]. *Journal of Neurology*, 249(12), 1738–1739.
<https://doi.org/10.1007/s00415-002-0898-7>
- Bekmanova, G., Yergesh, B., Sharipbay, A., & Mukanova, A. (2022). Emotional Speech Recognition Method Based on Word Transcription. *Sensors*, 22(5).
<https://doi.org/10.3390/s22051937>
- Bhardwaj, P., Gupta, P. K., Panwar, H., Siddiqui, M. K., Morales-Menendez, R., & Bhaik, A. (2021). Application of Deep Learning on Student Engagement in e-learning environments. *Computers and Electrical Engineering*, 93(August 2020), 107277.
<https://doi.org/10.1016/j.compeleceng.2021.107277>
- Cao, T., Liu, C., & Chen, J. (2021). Nonfrontal Expression Recognition in the Wild Based on PRNet Frontalization and Muscle Feature Strengthening. *Mathematical Problems in Engineering*, 2021, 1–21.
<https://doi.org/10.1155/2021/6620752>
- Chen, Y., Liu, S., Zhao, D., & Ji, W. (2023). Occlusion facial expression recognition based on feature fusion residual attention network. *Frontiers in Neurorobotics*, 17. <https://doi.org/10.3389/fnbot.2023.1250706>
- Chen, Y., Zhou, J., Gao, Q., Gao, J., & Zhang, W. (2023). MDNN: Predicting Student Engagement via Gaze Direction and Facial Expression in Collaborative Learning. *CMES - Computer Modeling in Engineering and Sciences*, 136(1), 381–401. <https://doi.org/10.32604/cmes.2023.023234>
- Cheong, J. H., Jolly, E., Xie, T., Byrne, S., Kenney, M., & Chang, L. J. (2023). Py-Feat: Python Facial Expression Analysis Toolbox. *Affective Science*, 4(4), 781–796. <https://doi.org/10.1007/s42761-023-00191-4>
- Eisenbarth, H., & Alpers, G. W. (2011). Happy Mouth and Sad Eyes: Scanning Emotional Facial Expressions. *Emotion*, 11(4), 860–865.
<https://doi.org/10.1037/a0022758>
- Engin, D., Ecabert, C., Ekenel, H. K., & Thiran, J. P. (2018). Face frontalization for cross-pose facial expression recognition. *European Signal Processing Conference, 2018-Septe*, 1795–1799.

- <https://doi.org/10.23919/EUSIPCO.2018.8553087>
- Freire-obregón, J. S. J. L. D., & Castrillón-santana, M. (2024). Multimodal emotion recognition based on a fusion of audiovisual information with temporal dynamics. *Multimedia Tools and Applications*.
<https://doi.org/10.1007/s11042-024-20227-6>
- Grahlow, M., Rupp, C. I., & Derntl, B. (2022). The impact of face masks on emotion recognition performance and perception of threat. *PLOS ONE*, 17(2), e0262840. <https://doi.org/10.1371/journal.pone.0262840>
- Gupta, S., Kumar, P., & Tekchandani, R. (2023a). A multimodal facial cues based engagement detection system in e-learning context using deep learning approach. *Multimedia Tools and Applications*, 82(18), 28589–28615.
<https://doi.org/10.1007/s11042-023-14392-3>
- Gupta, S., Kumar, P., & Tekchandani, R. (2023b). An optimized deep convolutional neural network for adaptive learning using feature fusion in multimodal data. *Decision Analytics Journal*, 8(May), 100277.
<https://doi.org/10.1016/j.dajour.2023.100277>
- Gupta, S., Kumar, P., & Tekchandani, R. K. (2023c). Facial emotion recognition based real-time learner engagement detection system in online learning context using deep learning models. *Multimedia Tools and Applications*, 82(8), 11365–11394. <https://doi.org/10.1007/s11042-022-13558-9>
- Hassner, T., Harel, S., Paz, E., & Enbar, R. (2015). Effective face frontalization in unconstrained images. *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, 07-12-June, 4295–4304. <https://doi.org/10.1109/CVPR.2015.7299058>
- Jain, V., & Learned-Miller, E. (2010). Fddb: A benchmark for face detection in unconstrained settings. *UMass Amherst Technical Report*, January.
http://works.bepress.com/erik_learned_miller/55/
- Jang, Y., Gunes, H., & Patras, I. (2019). Registration-free Face-SSD: Single shot analysis of smiles, facial attributes, and affect in the wild. *Computer Vision and Image Understanding*, 182(July 2018), 17–29.
<https://doi.org/10.1016/j.cviu.2019.01.006>
- Karimah, S. N., & Hasegawa, S. (2022). Automatic engagement estimation in smart education/learning settings: a systematic review of engagement definitions, datasets, and methods. *Smart Learning Environments*, 9(1).
<https://doi.org/10.1186/s40561-022-00212-y>
- Khoshnam, F., & Baraani-Dastjerdi, A. (2022). A dual framework for implicit and explicit emotion recognition: An ensemble of language models and computational linguistics. *Expert Systems with Applications*, 198(October 2021), 116686. <https://doi.org/10.1016/j.eswa.2022.116686>
- Kim, J., & Lee, D. (2023). Facial Expression Recognition Robust to Occlusion and to Intra-Similarity Problem Using Relevant Subsampling. *Sensors*, 23(5).
<https://doi.org/10.3390/s23052619>
- Li, S., & Deng, W. (2022). Deep Facial Expression Recognition: A Survey. *IEEE Transactions on Affective Computing*, 13(3), 1195–1215.
<https://doi.org/10.1109/TAFFC.2020.2981446>
- Li, S., Deng, W., & Du, J. P. (2017). Reliable crowdsourcing and deep locality-preserving learning for expression recognition in the wild. *Proceedings - 30th IEEE Conference on Computer Vision and Pattern Recognition*, CVPR

- 2017, 2017-Janua, 2584–2593. <https://doi.org/10.1109/CVPR.2017.277>
- Lin, H. C. K., Liao, Y. C., & Wang, H. T. (2022). Eye Movement Analysis and Usability Assessment on Affective Computing Combined with Intelligent Tutoring System. *Sustainability (Switzerland)*, 14(24). <https://doi.org/10.3390/su142416680>
- Liu, Z. T., Rehman, A., Wu, M., Cao, W. H., & Hao, M. (2021). Speech emotion recognition based on formant characteristics feature extraction and phoneme type convergence. *Information Sciences*, 563, 309–325. <https://doi.org/10.1016/j.ins.2021.02.016>
- Malakar, S., Chiracharit, W., & Chamnongthai, K. (2024). Masked Face Recognition with Generated Occluded Part using Image Augmentation and CNN Maintaining Face Identity. *IEEE Access*, 12(August), 126356–126375. <https://doi.org/10.1109/ACCESS.2024.3446652>
- Mamieva, D., Abdusalomov, A. B., Kutlimuratov, A., Muminov, B., & Whangbo, T. K. (2023). Multimodal Emotion Detection via Attention-Based Fusion of Extracted Facial and Speech Features. *Sensors*, 23(12). <https://doi.org/10.3390/s23125475>
- Mao, J., Qian, Z., & Lucas, T. (2023). Sentiment Analysis of Animated Online Education Texts Using Long Short-Term Memory Networks in the Context of the Internet of Things. *IEEE Access*, 11(August), 109121–109130. <https://doi.org/10.1109/ACCESS.2023.3321303>
- Mattioli, M., & Cabitza, F. (2024). Not in My Face: Challenges and Ethical Considerations in Automatic Face Emotion Recognition Technology. *Machine Learning and Knowledge Extraction*, 6(4), 2201–2231. <https://doi.org/10.3390/make6040109>
- Mehta, N. K., Prasad, S. S., Saurav, S., Saini, R., & Singh, S. (2022). Three-dimensional DenseNet self-attention neural network for automatic detection of student's engagement. *Applied Intelligence*, 52(12), 13803–13823. <https://doi.org/10.1007/s10489-022-03200-4>
- Mensah, J. A., Nortey, E. N. N., Ocran, E., Iddi, S., & Asiedu, L. (2024). De-occlusion and recognition of frontal face images: a comparative study of multiple imputation methods. *Journal of Big Data*, 11(1). <https://doi.org/10.1186/s40537-024-00925-6>
- Mollahosseini, A., Hasani, B., & Mahoor, M. H. (2019). AffectNet: A Database for Facial Expression, Valence, and Arousal Computing in the Wild. *IEEE Transactions on Affective Computing*, 10(1), 18–31. <https://doi.org/10.1109/TAFFC.2017.2740923>
- Morar, A., Moldoveanu, F., Moldoveanu, A., & Oana Balan, V. A. (2017). GPU accelerated 2D and 3D image processing. *Proceedings of the 2017 Federated Conference on Computer Science and Information Systems, FedCSIS 2017*, 11, 653–656. <https://doi.org/10.15439/2017F265>
- Pan, T., Ye, Y., Zhang, Y., Xiao, K., & Cai, H. (2024). Online multi-hypergraph fusion learning for cross-subject emotion recognition. *Information Fusion*, 108(February), 102338. <https://doi.org/10.1016/j.inffus.2024.102338>
- Peterson, A. T. (2023). Asynchrony and promotive interaction in online cooperative learning. *International Journal of Educational Research Open*, 5(September), 100300. <https://doi.org/10.1016/j.ijedro.2023.100300>
- Poux, D., Allaert, B., Ihaddadene, N., Bilasco, I. M., Djeraba, C., & Bennamoun,

- M. (2022). Dynamic Facial Expression Recognition under Partial Occlusion with Optical Flow Reconstruction. *IEEE Transactions on Image Processing*, 31, 446–457. <https://doi.org/10.1109/TIP.2021.3129120>
- Pu, M., Chong, C. Y., & Lim, M. K. (2023). Robustness Evaluation in Hand Pose Estimation Models using Metamorphic Testing. *2023 IEEE/ACM 8th International Workshop on Metamorphic Testing (MET)*, 31–38. <https://doi.org/10.1109/MET59151.2023.00012>
- Qu, Z., Shang, X., Xia, S. F., Yi, T. M., & Zhou, D. Y. (2022). A method of single-shot target detection with multi-scale feature fusion and feature enhancement. *IET Image Processing*, 16(6), 1752–1763. <https://doi.org/10.1049/ipr2.12445>
- Rathod, M., Dalvi, C., Kaur, K., Patil, S., Gite, S., Kamat, P., Kotecha, K., Abraham, A., & Gabralla, L. A. (2022). Kids' Emotion Recognition Using Various Deep-Learning Models with Explainable AI. *Sensors*, 22(20). <https://doi.org/10.3390/s22208066>
- Roy-Charland, A., Perron, M., Beaudry, O., & Eady, K. (2014). Confusion of fear and surprise: A test of the perceptual-attentional limitation hypothesis with eye movement monitoring. *Cognition and Emotion*, 28(7), 1214–1222. <https://doi.org/10.1080/02699931.2013.878687>
- Ruan, L., Han, Y., Sun, J., Chen, Q., & Li, J. (2022a). Facial expression recognition in facial occlusion scenarios: A path selection multi-network. *Displays*, 74(June), 102245. <https://doi.org/10.1016/j.displa.2022.102245>
- Ruan, L., Han, Y., Sun, J., Chen, Q., & Li, J. (2022b). Facial expression recognition in facial occlusion scenarios: A path selection multi-network. *Displays*, 74, 102245. <https://doi.org/10.1016/j.displa.2022.102245>
- Santoni, M. M., Basaruddin, T., Junus, K., & Lawanto, O. (2024). Automatic Detection of Students' Engagement During Online Learning: A Bagging Ensemble Deep Learning Approach. *IEEE Access*, 12(June), 96063–96073. <https://doi.org/10.1109/ACCESS.2024.3425820>
- Shi, L. (2024). The Integration of Advanced AI-Enabled Emotion Detection and Adaptive Learning Systems for Improved Emotional Regulation. *Journal of Educational Computing Research*, 63(1), 173–201. <https://doi.org/10.1177/07356331241296890>
- Shobana, B. T., & Kumar, G. A. S. (2021). I-Quiz: An Intelligent Assessment Tool for Non-Verbal Behaviour Detection. *Computer Systems Science and Engineering*, 40(3), 1007–1021. <https://doi.org/10.32604/CSSE.2022.019523>
- Sowjanya, U. L., & Krithiga, R. (2024). Decoding Student Emotions: An Advanced CNN Approach for Behavior Analysis Application Using Uniform Local Binary Pattern. *IEEE Access*, 12(August), 106273–106284. <https://doi.org/10.1109/ACCESS.2024.3436531>
- Sukumaran, A., & Manoharan, A. (2024). Multimodal Engagement Recognition From Image Traits Using Deep Learning Techniques. *IEEE Access*, 12(December 2023), 25228–25244. <https://doi.org/10.1109/ACCESS.2024.3353053>
- Taigman, Y., Yang, M., Ranzato, M., & Wolf, L. (2014). DeepFace: Closing the gap to human-level performance in face verification. *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, 1701–1708. <https://doi.org/10.1109/CVPR.2014.220>

- Tariyal, S., Chauhan, R., Bijalwan, Y., Rawat, R., & Gupta, R. (2024). A comparative study of MTCNN, Viola-Jones, SSD and YOLO face detection algorithms. *2024 International Conference on Intelligent and Innovative Technologies in Computing, Electrical and Electronics (IITCEE)*, 1–7. <https://doi.org/10.1109/IITCEE59897.2024.10467445>
- Tian, X., Nunes, B. P., Liu, Y., & Manrique, R. (2024). Predicting Student Engagement Using Sequential Ensemble Model. *IEEE Transactions on Learning Technologies*, 17, 939–950. <https://doi.org/10.1109/TLT.2023.3342860>
- Tsai, K. Y., Tsai, Y. W., Lee, Y. C., Ding, J. J., & Chang, R. Y. (2021). Frontalization and adaptive exponential ensemble rule for deep-learning-based facial expression recognition system. *Signal Processing: Image Communication*, 96(April), 116321. <https://doi.org/10.1016/j.image.2021.116321>
- Ullah, S., Ou, J., Xie, Y., & Tian, W. (2024). Facial expression recognition (FER) survey: a vision, architectural elements, and future directions. *PeerJ Computer Science*, 10. <https://doi.org/10.7717/PEERJ-CS.2024>
- Villegas-Ch, W., Garcia-Ortiz, J., & Sanchez-Viteri, S. (2024). Personalization of Learning: Machine Learning Models for Adapting Educational Content to Individual Learning Styles. *IEEE Access*, 12(July), 121114–121130. <https://doi.org/10.1109/ACCESS.2024.3452592>
- Wang, S. (2021). Online learning behavior analysis based on image emotion recognition. *Traitement du Signal*, 38(3), 865–873. <https://doi.org/10.18280/ts.380333>
- Wickline, V. B., Hall, A. S., Lavrisa, R., McCook, K., Woodcock, M., Bani, M., Strepparava, M. G., Russo, S., & Nowicki, S. (2025). Facial occlusion with medical masks: Impacts on emotion recognition rates for emotion types and intensities. *Quarterly Journal of Experimental Psychology*. <https://doi.org/10.1177/17470218241308569>
- Xu, Z. (2023). Application of Convolution Neural Network Algorithm in Online Education Emotion Recognition. *International Journal of Web-Based Learning and Teaching Technologies*, 18(2), 1–13. <https://doi.org/10.4018/IJWLTT.331077>
- Yu, S., Androsov, A., Yan, H., & Chen, Y. (2024). Bridging computer and education sciences: A systematic review of automated emotion recognition in online learning environments. *Computers and Education*, 220(3663), 105111. <https://doi.org/10.1016/j.compedu.2024.105111>
- Zeng, H., Shu, X., Wang, Y., Wang, Y., Zhang, L., Pong, T. C., & Qu, H. (2021). EmotionCues: Emotion-Oriented Visual Summarization of Classroom Videos. *IEEE Transactions on Visualization and Computer Graphics*, 27(7), 3168–3181. <https://doi.org/10.1109/TVCG.2019.2963659>
- Zhang, N., Liu, N., Han, J., Wan, K., & Shao, L. (2023). Face De-Occlusion With Deep Cascade Guidance Learning. *IEEE Transactions on Multimedia*, 25, 3217–3229. <https://doi.org/10.1109/TMM.2022.3157036>
- Zhang, X., & Qin, X. (2022). Research on Sentiment Analysis Algorithm for Comments on Online Ideological and Political Courses. *International Journal of Advanced Computer Science and Applications*, 13(11), 174–179. <https://doi.org/10.14569/IJACSA.2022.0131119>

- Zhang, X., Zhang, F., & Xu, C. (2022). Joint Expression Synthesis and Representation Learning for Facial Expression Recognition. *IEEE Transactions on Circuits and Systems for Video Technology*, 32(3), 1681–1695. <https://doi.org/10.1109/TCSVT.2021.3056098>
- Zhu-Zhou, F., Gil-Pita, R., García-Gómez, J., & Rosa-Zurera, M. (2022). Robust Multi-Scenario Speech-Based Emotion Recognition System. *Sensors*, 22(6). <https://doi.org/10.3390/s22062343>
- Zhu, C., Wan, X., Xie, S., Li, X., & Gu, Y. (2022). Occlusion-robust Face Alignment using A Viewpoint-invariant Hierarchical Network Architecture. *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 2022-June*, 11102–11111. <https://doi.org/10.1109/CVPR52688.2022.01083>
- Zhu, K., He, X., Lv, Z., Zhang, X., Hao, R., He, X., Wang, J., He, J., Zhang, L., & Mu, Z. (2023). A 3D Occlusion Facial Recognition Network Based on a Multi-Feature Combination Threshold. *Applied Sciences (Switzerland)*, 13(10). <https://doi.org/10.3390/app13105950>

LAMPIRAN

Lampiran A Algoritma fungsi utama metode usulan (*Half-Flip 2D*)

Masukan:

I_{in} (wajah teroklusi tangan atau wajah *non-frontal*)

Langkah 1: // *koreksi arah kepala (roll)*

$I_{rot} \leftarrow \text{RotateForRollCorrection}(I_{in})$

Langkah 2: // *landmarking wajah dan tangan*

$L_{face}, L_{hand} \leftarrow \text{DetectLandmarks}(I_{rot})$

$I_{src} \leftarrow I_{rot}$

Langkah 3: // *masking wajah dan tangan, masking putih untuk wajah dan merah untuk tangan*

$M_{face} \leftarrow \text{CreateFaceMask}(I_{rot}, L_{face}, \text{WHITE})$

if $L_{hand} = \text{TRUE}$ **then**

$M_{hand} \leftarrow \text{CreateHandMask}(I_{rot}, L_{hand}, \text{RED})$

$I_{src} \leftarrow \text{ApplyHandBlurring}(I_{rot}, L_{hand})$

$M_{full} \leftarrow \text{CombineMasks}(M_{face}, M_{hand})$

else

$M_{full} \leftarrow M_{face}$

end if

Langkah 4: // *membagi wajah menjadi 2 bagian*

$M_{left}, M_{right} \leftarrow \text{DivideByCenter}(M_{full}, L_{face})$

$CM_{left} \leftarrow \text{CountWhitePixels}(M_{left})$

$CM_{right} \leftarrow \text{CountWhitePixels}(M_{right})$

Langkah 5: // *membandingkan luas 2 bagian wajah*

if $CM_{left} > CM_{right}$ **then**

$M_{sel} \leftarrow M_{left}$

else

$M_{sel} \leftarrow M_{right}$

end if

Langkah 6: // *meluruskan bagian tengah wajah yang terpotong pada bagian wajah pilihan*

$M_{stretch} \leftarrow \text{StretchToStraightLine}(M_{sel})$

Langkah 7: // *mengganti masking wajah dengan wajah asli*

$I_{sel} \leftarrow \text{ReplaceRegion}(I_{src}, M_{stretch})$

Langkah 8: // *duplikasi dan membalikkan gambar wajah pilihan*

$I_{flip} \leftarrow \text{DuplicateFlipHorizontal}(I_{sel})$

Langkah 9: // *mengkombinasikan hasil dari langkah 7 dan 8 lalu merubah ukurannya*


$I_{full} \leftarrow \text{Combine}(I_{sel}, I_{flip})$

$I_{out} \leftarrow \text{ResizeImage}(I_{full}, 224, 224)$


Keluaran: I_{out} (wajah tanpa oklusi dan menghadap ke depan)

Lampiran B Hasil pengujian evaluasi tingkat *engagement*


- Hasil pengujian pemelajar 1




Engagement Siswa



Persentase Emosi







Kesimpulan



Grafik per emosi



- Hasil pengujian pemelajar 2



- Hasil pengujian pemelajar 3

